TÜBİTAK
ARAŞTIRMA PROJESİ
GELİŞME RAPORU
(*Bilimsel Rapor*)

PROJE NO	**: 215E248**
RAPOR NO	**: 3. Gelişme Raporu**
RAPOR DÖNEMİ	**: 01/5/18 - 30/7/19**
PROJE YÜRÜTÜCÜSÜ	**: A. Murat Özbayoğlu**

BİLİMSEL RAPORDA OLMASI GEREKEN BİLGİLER

Dönem içinde projeyle ilgili bilimsel ve teknik gelişmeler proje planı ile karşılaştırılarak verilmeli, elde edilen veriler ile varılan ara sonuçlar, varsa materyal, yöntem ve kapsam değişikleri belirtilmeli ve tartışılmalıdır.
Dönem içindeki idari gelişmeler (yardımcı araştırıcı ve personel değişikliği, ek süre, yürütücünün kurum değişikliği ve varsa diğer destekleyen kuruluşlarla sürdürülen işbirliği, vb. konularındaki bilgiler) verilmelidir.
Proje çalışmaları kabul edilen çalışma takvimine uygun yürümüyorsa gerekçeleri açıklanmalıdır.
Bir sonraki dönem içinde yapılması planlanan çalışmalar (öneri formundan farklı bir durum oluşmuş ise) belirtilmelidir.
Destekleyen diğer kuruluşlarla ilgili sorunlar var ise ayrıntıları ve çözüm önerileri sunulmalıdır.

Bilgi Notu:

- TÜBİTAK tarafından kabul edilebilir geçerli bir mazeret bildirilmeksizin; proje gelişme raporlarının sözleşmede belirtilen tarihlerde, proje sonuç raporlarının ise, sözleşmede belirtilen proje bitiş tarihinden itibaren 2 (iki) ay içinde gönderilmemesi halinde, ilgili rapor dönemine ait Proje Teşvik İkramiyeleri (PTİ) ödenmeyecektir.

- Proje ekibi tarafından, TÜBİTAK desteği ile yürütülmekte/sonuçlandırılmış olan projeler kapsamında yapılan yayınlarda [makale, kitap, bildiri (sözlü sunum/poster sunum), tez, yayılım vb.] proje sözleşmesi ve TÜBİTAK Araştırma ve Yayın Etiği Kurulu Yönetmeliği (AYEK) gereğince ilgili proje numarası ile birlikte TÜBİTAK desteği belirtilmelidir.

- 03/11/2012 tarihinden sonra sonuçlanan projelerde, projelerin yürütücü ve araştırmacılarını ödüllendirmek amacıyla Proje Performans Ödülü (PPÖ; ppo.tubitak.gov.tr) uygulamasına başlanmıştır. Bu uygulamaya paralel olarak proje çıktılarının değerlendirilmesi de ARDEB Proje Takip Sistemi (ardeb-pts.tubitak.gov.tr) üzerinden yapılmaktadır. Bu kapsamda projenize ait çıktıların PTS'ye yüklenmesi önem taşımaktadır.

BİLİMSEL GELİŞME RAPORU EK SAYFASI
(Proje No: 215E248)

(Her madde için gerektiği kadar alan ve ek sayfa kullanabilirsiniz)

1. Dönem İçinde Projeyle İlgili Bilimsel ve Teknik Gelişmeler

Bu rapor, proje kapsamında 4. Altı aylık Döneme denk gelen (19-24 aylar arası) 1.11.2017 - 30.4.2018 arasında yapılan çalışmaları kapsamaktadır. Bu dönem içinde önceki dönemlerde başlanmış çalışmalara devam edilmiştir. Bu dönem itibarıyle projedeki tüm iş paketleri üzerinde öngörülen çalışmalara başlanmıştır ve bunların bir kısmında önemli kazanımlar elde edilecek seviyelere gelinmiştir. Proje ekibinde yine bazı değişiklikler olmuş, buna bağlı olarak çalışmaların aksamaması için proje takviminde bu yapılanmaya uygun olacak şekilde düzenlemeler yapılmıştır. Şu an itibarıyle proje çalışmaları genel olarak öngörülen yapıya uygun ilerlemektedir. Bu dönem boyunca gerçekleştirilen çalışmalar ve elde edilen bilimsel ve teknik gelişmeler bu bölümde detaylandırılmıştır.

Dönem başlangıcında proje ekibi yürütücü Yrd. Doç. Dr. Murat Özbayoğlu, doktora bursiyeri Mehmet Uğur Güdelek (burslu), yüksek lisans bursiyerleri Efe Arın (burslu ücretli) ve Mustafa Mert Keskin (burslu)'dan oluşmaktaydı. Kaan Kaya projede kısa bir süre çalıştı ve Ocak ayı içinde projeden ayrıldı. Kaan Kaya'nın projede ağırlıklı olarak IP6 kapsamında gerçekleştirilecek çalışmalarda katkı sağlaması planlanmıştı. Bu dönem içinde aynı iş paketi kapsamındaki faaliyetlerde çalışmak üzere bir başka burslu ücretli yüksek lisans öğrencisi Gökçe Dilek Kısbet projeye dahil edilmiştir. Benzer şekilde bir başka burslu ücretli yüksek lisans öğrencisi Betül Bakar da bu dönem içinde proje ekibinde çalışmaya başlamıştır.

Projenin bu döneminde tüm iş paketleri üzerinde çalışmalar yapılmıştır. Proje takvimine göre IP1 trend tahmini, IP2 teknik analiz eniyilemesi ve IP5 büyük veri analizi iş paketleri tamamlanmıştır. Başarı kriterleri göz önüne alındığında IP1 ve IP2 için öngörülen değerlere ulaşılmasına rağmen, bu iş paketlerinin sonuçlarındaki iyileşmenin projenin genel performansına önemli pozitif etki yapacağı düşünüldüğünde bu iş paketleri kapsamındaki modeller ve algoritmalar üzerindeki çalışmalar devam etmektedir. IP5 büyük veri analizi iş paketindeki çalışmalara başlanmış, fakat henüz kaydadeğer bir ilerleme sağlanmamıştır. Fakat diğer tüm iş paketlerinde önemli kazanımlar elde edilmiştir.

1.A. Dönem İçinde Projeyle İlgili Bilimsel Gelişmeler:

Bu dönem içinde tüm iş paketleri üzerinde çalışmalar gerçekleştirilmiştir. Yapılan her çalışmanın hangi iş paketi kapsamında gerçekleştirildiği de verilmiştir.

- Trend ve değer tahmini için zaman serisi tabanlı verilere bağlı tahmin ajanları kullanımı (IP1)
- Sezgisel destek-direnç çizgileri yaklaşımı (IP1)
- Spark (büyük veri platformu) üzerinde performans testleri (IP5)
- Opsiyon alım-satım sinyali oluşturulması (IP7)
- Baştan sona hızlı prototip geliştirme yazılımı (IP8)

Proje kapsamında yer alan tüm iş paketlerindeki çalışmalar projenin son 6 aylık döneminde de devam edecektir. Bu dönem içinde daha önceden kabul edilmiş olan 2 adet konferans bildirisi 2017 IEEE Symposium on Computational Intelligence for Financial Engineering & Economics (IEEE CIFEr'17) ve Complex Adaptive Systems (CAS 2018) yayınlanmıştır. Aynı şekilde bu dönem içinde derin öğrenme ile Trend tahmini ve alım-satım modeliyle elde ettiğimiz sonuçların sunulduğu bir makalemiz SCI endeksli Applied Soft Computing dergisinde basılmak üzere kabul edildi. Bir SCI-Expanded dergisine (Intelligent Automation and Soft Computing) gönderdiğimiz bir başka makale de hakem incelemesindedir. Şu anda bir başka dergi makalesi üzerinde çalışmaya başladık. Yine bu sene içinde bir tane daha dergi makalesi hazırlamayı planlıyoruz.
2 adet review – dergi
1 adet agent paper – dergi ? konferans
1 adet destek direnç çizgileri – konferans?
1 adet opsiyon al-sat (efe) – konferans ?

Bu bilgilerin ışığı altında bu dönem içinde yapılan çalışmaların detayları ilerleyen sayfalarda verilmiştir. Yapılan çalışmaların bazıları birden fazla iş paketini kapsadığı için çalışmalar konu bazlı gruplandırılarak açıklanacaktır.

1.A.1. IP6 Çalışmaları (Mert)

1.A.1.1. Çok Etmenli (Multi-agent) Model Geliştirilmesi

Bu iş paketinde bir finans zaman serisinin birden çok yapay zeka ile aynı anda çalıştırılması ve bu yapay zekaların verdikleri kararları değerlendirip geliştirecek bir karar verici mekanizma tasarlanması planlanmıştır. Her bir yapay zekanın ayrı ayrı tasarlanmış olduğu bu bölümde karar verici mekanizma diğer yapay zekaların üretmiş olduğu kararlara bakarak daha iyi bir sonuç elde etmeye çalışmıştır. Teoride birden çok zekanın iyi ve kötü özelliklerine bakılarak doğrusal bir kombinasyonu ya da karmaşık birleştirmeler yardımıyla daha iyi bir sonuç elde edilmeye çalışılmıştır. Mantığın doğruluğu yapılan analizler sonucunda ispatlanmıştır fakat finans sinyalinin tespitinin zor olmasından dolayı bu tezi doğrulamak amacıyla bu durum daha analizi kolay olan bir veri olan hava durumu verisi üzerinde çalışılmıştır.

Literatür taraması ne tarz yapay zekalar oluşturulabilir bu araştırılmış daha önce yapılan benzer bir çalışma olup olmadığına bakılmıştır. Bu iş paketinde referans olarak diğer yapay zekalardan daha iyi sonuç verebilecek olan bir yapay zeka tasarlanması hedeflenmiştir.

Bu iş paketinde öne çıkan başlıklar şu şekildedir:

- Zaman serisi ile tahmin yapabilen modeller, açıklamaları ve projede uygulanması
- Veriye yapılan ön işlemler
- Oluşturulan yapay zekalara tasarlanan karar verici mekanizmalar
- Sonuçlar ve karşılaştırılması

1.A.1.2. Zaman serisi ile tahmin yapabilen modeller ve projede uygulanması

Dünya üzerinde zaman serisi tahmini yapabilen birçok modeller bulunmaktadır. Bunlardan en çok bilinenleri zaman serisinden geleceği tahmin etme işlemi yapılmıştır. Burada amaç gelecekteki günlerde hava durumu sıcaklığı veya para miktarının artış yüzdesinin tahmin edebilecek modeller tasarlamaktır. Problem burada sadece bir veri ile düşünülmemiştir yani zaman serisi olabilecek her hangi bir veri üzerinde çalışabilecek şekilde düşünülmüştür.
Burada en temel olarak kullanılan modeller şunlardır:

- ARIMA(Otoregresif hareketli ortalamalar)
- RSI (Göreceli güç endeksi)
- Multilayer perceptron(Çok katmanlı yapay sinir ağı) ve farklı şekilde tasarlanmış hali
- Lineer regression(Doğrusal Regresyon)

Bu tasarlanan modeller gelecekteki verileri sürekli tahmin etmeye çalışacaklar ve bu modellerin üretmiş olduğu çıktılar incelenerek daha iyi bir sonuç elde etmek hedeflenmektedir. Bu modeller temel çalışma prensipleri diğer başlıklar içerisinde yer almaktadır.

1.A.1.2.1. ARIMA(Otoregresif hareketli ortalamalar)

ARIMA zaman serisi tahmini için birçok alanda kullanılmakta olan bir modeldir. Aslında geleceği tahmin şu anki verilerin ortalamasına bakarak tahmin etmektedir. ARMA'nın geliştirilmiş bir halidir. ARIMA 'nın AR özelliği gecikme miktarını,I kısmı verilerin o anki değerleri ve önceki değerleri ile farkı ile değiştirilmesini , MA ise ortalama hata hesaplarken kullanılmakta olan bir kısımdır. Bu şekilde hatanın etki miktarını değiştirmektedir fakat bir gecikme miktarına sebep olmaktadır.
Burada ARIMA ilk aşamada (0,1,0) için kullanılmıştır. Bu formatta ARIMA'nın formülü şu şekilde olmaktadır:

$$\hat{Y}_t - Y_{t-1} = \mu$$

ARIMA modelinde bu dereceler daha farklı sonuçlar oluşturabilir. Bu rastgele yürüyüş(random walk) için denenmekte olan ve projede yeterli bir miktarda sonuç üretmeye yeterli olmuş olan bir model oluşturmaktadır. Verinin yapısına göre daha iyi sonuç almak veya farklı mantıkta yapay zekalar oluşturmak için farklı katsayılar kullanılabilir.

1.A.1.2.2. RSI(Göreceli güç endeksi)

RSI genellikle finans üzerinde yüksek bir şekilde satın al ya da yükse bir şekilde sat gibi komutlar üretebilen bir modeldir. Özelikle verinin belirli eğilimlerde olduğu dönemlerde daha mantıklı sonuç üretebilen RSI burada finans tahmini ve yapılacak olan destekleyici modellerin incelenmesi için kullanılacak olan hava durumu verisinde de kullanılmıştır.
RSI aşağıdaki gibi hesaplanmaktadır:
RSI= 100 - (100/(1+RS))
RS= AUn / ADn

AUn = önceki n gün zaman içerisindeki o anki verinin değerinden daha yukarıda olan verilerin ortalamasıdır.
ADn = önceki n gün zaman içerisindeki o anki verinin değerinden daha aşağıda olan verilerin ortalamasıdır.

Bu hesaplama sonucunda oluşan RSI değeri 0 ile 100 arasındaki sayılara karşılık gelmektedir. Bu sayı eğer 70'den büyük ise verinin gelecekte artacağını 30'dan küçük ise verinin artacağına işaret etmektedir. Bu iş paketinde yapılan çalışma gereği problemin sadece artış ve azalış gerçekleşmesinden ziyade tam olarak bir yüzde artış miktarı üretilmesi gerekmektedir. Yani bu 0-100 arası oluşturulan sayının -100 ile 100 arasına eşleştirilmesi gerekmektedir. Gerçek RSI modelinden farklı olan yanı ise sanki sürekli zamanda değer üretiyormuşçasına değer üretmesidir.

1.A.1.2.3. Lineer Regression(Doğrusal Regresyon)

Doğrusal regresyon modeli doğrusal bir ayırıcı yüzey sayesinde ya da tahmin mekanizması sayesinde gelecekteki verileri tahmin eden bir modeldir. Belirli katsayıları ve rastgele gürültünün tespiti için eklenmekte olan bir terimi bulunmaktadır. Bunlar sayesinde gelecekteki verinin en doğru şekilde tespitini sağlamaktadır. Fakat bu çözüm basit veri tipleri için geçerli olmaktadır. Lineer regresyon sonucunda da doğrusal olarak oluşturacak olan bu model büyük değişimleri tahmin etmekte zorlanacak bir modeldir. Genel olarak tüm verilere uygun olan bir parametre uydurma işlemi yapmasından dolayı diğer modellerden farklı olarak çalışmaktadır. Bu farklı mantıkta çalışma prensibi yapılacak olan deney için büyük bir önem taşımaktadır.

$$y_i = \beta_0 1 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i = \mathbf{x}_i^{\mathsf{T}} \boldsymbol{\beta} + \varepsilon_i, \qquad i = 1, \ldots, n,$$

Bu yapılacak olan işlemim matris formatındaki gösterimi aşağıdaki gibi olacaktır. Burada y'ler tahmin edilecek olan veriler, x'ler ise girdiler, ϵ ise oluşturulmuş olan gürültü rastgele değişkenidir. Matris gösteriminin sağladığı fayda daha kolay bir hesaplama yapılmasını sağlamaktadır.

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

$$X = \begin{pmatrix} \mathbf{x}_1^{\mathsf{T}} \\ \mathbf{x}_2^{\mathsf{T}} \\ \vdots \\ \mathbf{x}_n^{\mathsf{T}} \end{pmatrix}$$

$$\boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix}$$

$$\boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

Bu tahmin edilecek olan verilerin gerçek değer ile arasındaki farklara bakılarak en uygun parametreler bulunmaya çalışılmıştır ve bu modelde oluşturulacak olan deneye eklenmiştir.

1.A.1.2.4. Multilayer perceptron(Çok katmanlı yapay sinir ağı)

Çok katmanlı yapay sinir ağı bu projede iki farklı şekilde kullanılmıştır. Bunlardan birisinde veri üzerinden çıkarılmış olan bilgiler yardımıyla eğitim ve tahmin işlemi yapılmıştır. Diğerinde ise veriler belirli bir kısıt uzunluğu ile beslenerek eğitim yapılmıştır yani her örnek anındaki veriler belirli bir geçmiş bilgisi ile birleştirilerek yeni bir tahmin

edici mekanizma kurulmuştur. Bu model diğer modeller çok farklı bir yaklaşım olmak ile birlikte deneye farklı bir bakış açısı kazandırmaktadır.
Öznitelikler yardımıyla eğitilecek olan çok katmanlı yapay sinir ağının öz nitelik girdileri şunlardır ve bu öz nitelikler belirli bir pencere uzunluğu içerisinden bakılarak çıkarılmaktadır.

- Pencerenin içerisindeki ilk veri
- Pencerenin içerisindeki son veri
- Pencerenin içerisindeki ortanca veri
- Penceredeki 0'dan büyük elemen sayısı
- Penceredeki 0'dan küçük eleman sayısı
- Penceredeki verilerin varyansı
- Penceredeki verilerin ortalaması

Yapay sinir ağlarını genel olarak ifade eden formüller aşağıdaki gibidir.

$$p_j(t) = \sum_i o_i(t) w_{ij}$$

$$p_j(t) = \sum_i o_i(t) w_{ij} + w_{0j}$$

Yukarıdaki tanımlamalar yapay sinir ağının ileri besleme kısmını tanımlamaktadır. Aşağıdaki formüller ise geri besleme kısmını tanımlamaktadır. Geri besleme yapılırken en yakın kare açılımına bakılmaktadır. Böylelikle hata minimize edilmektedir. Bu yapay sinir ağının birden çok katmanı bulunmaktadır. İki gizli katmanı,1 giriş katmanı ve çıkış katmanından oluşmak olan bu sinir ağı f(x) ile y arasındaki farkı minimize etmeye çalışmaktadır.
İki ayrı tasarlanan model içinde aynı durum söz konusudur. Modeller bu şekilde çalışmaktadır fakat girdi katmanlarının boyutu farklı ve girilen girdilerde birbirinden farklı konumdadır.
Modellerin birisinde giriş katmanındaki nöron sayısı 11 iken doğrudan veri ile beslenen modelin giriş katmanındaki nöron sayısı 40 adettir.

$$C = E\left[(f(x) - y)^2\right]$$

$$\hat{C} = \frac{1}{N} \sum_{i=1}^{N} (f(x_i) - y_i)^2$$

$$w_{ij}(t+1) = w_{ij}(t) - \eta \frac{\partial C}{\partial w_{ij}} + \xi(t)$$

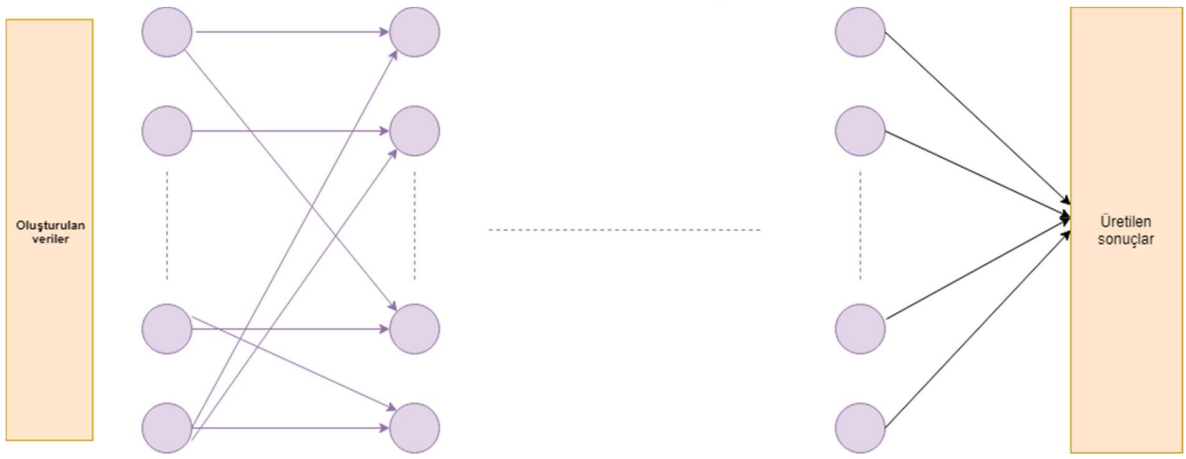

Şekil 1. İki model içinde oluşturulmuş olan bir örnek yapay sinir ağı modellemesi

1.A.1.3. Veriye yapılan ön işlemler

Burada veri bir zaman serisi olarak ele alınmaktadır. Bu yüzden dolayı belirli değeri olan veriler bulunmaktadır. Eğer finans için yapılmış olan bir veri seti var ise hisse değeri, hava durumu gibi bir veri varsa da sıcaklık gibi bilgiler saatlik, günlük, haftalık bir şekilde depolanmaktadır. Bu verilerin zaman içerisindeki değişimlerin incelenebilmesi amacıyla bu çalışmada veriler birbirleri arasındaki farklara göre yüzdelik artış miktarlarına dönüştürülmüşlerdir.

Bu şekilde -100 ile 100 arasında sayılardan oluşan ve bir sonraki gün için artış miktarı olarak bilgi taşıyabilecek bir hale dönüştürülmüştür. Bu normalleştirme durumu genel olarak zaman serisi verileri üzerinde fark oluşturduğundan ve sayıları da belirli bir skalada tutmasından dolayı bu çalışmada kullanılmıştır.

1.A.1.4. Oluşturulan yapay zekalara tasarlanan karar verici mekanizmalar

Bu bölümde bu projenin asıl amacı olan bir karar verici mekanizmanın nasıl oluşturulduğu açıklanacaktır. Bunun yanı sıra tasarlanmış olan bu karar verici mekanizmanın doğru bir şekilde karşılaştırılabilmesi için yeni karar verici mekanizmalar tasarlanmıştır. B
Projedeki temel fikir birden çok karar verebilen agentlar(ajan,etken) tasarlanmış iken bunların kararlarına bakarak gerçek zaman serisi bilgisine bakmaksızın daha iyi bir sonuç etmektir. Burada sistemin geçmiş zaman tepkisine bakaraktan daha iyi bir sonuç elde edilebilir. Bundan dolayı tasarlanacak olan model geçmiş bilgisinden iyi sonuç elde edebilecek olan bir model olmak zorunadır. Bu işi yapabilecek olan en iyi model LSTM(uzun kısa süreli bellek)'tir. Bu LSTM'in yanı sıra adaletli bir karşılaştırma yapabilmemiz için Multilayer Perceptron Decider ve Majority Voter(Çoğunluk oylayıcı) tasarlanmıştır.
Bu karar verici mekanizmaların işleyişi ve genel mantıkları diğer başlıklardadır.

1.A.1.4.1. LSTM Karar Verici Mekanizması

LSTM zaman sıralı diziler üzerinden örüntü tanıyabilen modellerdir. Normal derin öğrenme veya yapay sinir ağından en büyük farkı birbirleri ile zaman bağlı ilişkisi bulunan hücrelerin bulunmasıdır. Bu hücrelerin yardımıyla hafızalı bir tanıma işlemi yapılmaktadır. Burada çalışmakta olan yapay zekaların zamana göre kararları incelenerek en mantıklı kararı veren yapay zekanın takip edilmesi hedeflenmektedir. Bu yüzden dolayı da LSTM gibi hafızalı bir derin öğrenme modeli kullanmak en mantıklı olan seçimdir.

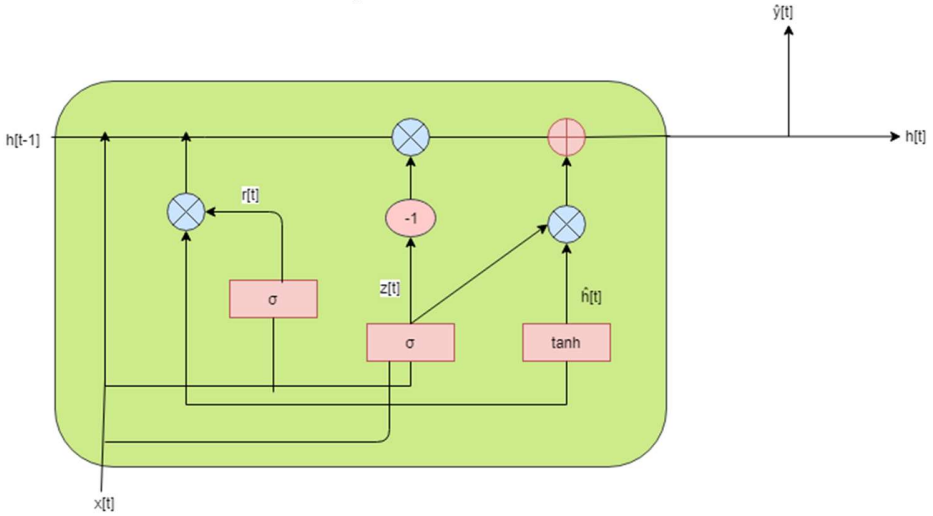

Şekil 2. LSTM hücresinin örnek hali

$$z_t = \sigma_g(W_z x_t + U_z h_{t-1} + b_z)$$

$$r_t = \sigma_g(W_r x_t + U_r h_{t-1} + b_r)$$

$$H_t = (1 - Z_t) \cdot H_{t-1} + Z_t \cdot \sigma_h(W_h X_t + U_h(R_t \cdot H_{t-1}) + B_h)$$

$$h_t = (1 - z_t) \cdot h_{t-1} + z_t \cdot \sigma_h(W_h x_t + U_h(r_t \cdot h_{t-1}) + b_h)$$

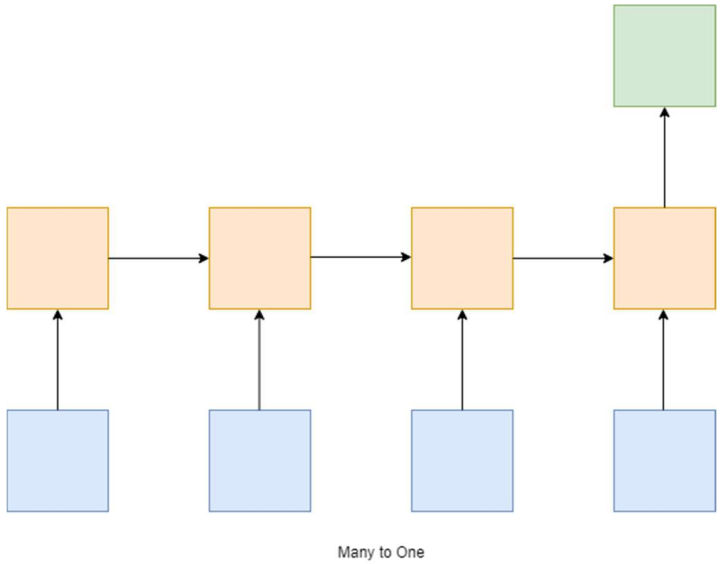

Şekil 3. Projede kullanılan LSTM Modelinin genel iskelet yapısı

Burada birden çok girdiye karşın yalnızca bir çıktı üretilerek en doğru kararın ne olduğu araştırılmaktadır. Bu tarz çalışmakta olan sistemler many to one olarak isimlendirilmektedir. Girdi olarak verilmiş olan kısıt uzunluğu L = 25 olarak belirlenmiş ve son 25 günlük üretilen kararlar sürekli olarak değerlendirilerek karar elde edilmeye çalışılmaktadır. Bu LSTM ağı çoklu kanal ile çalışmaktadır. Böylelikle oluşturulmakta olan matrisler hem bir sıralı dizi hem de o anki tüm yapay zekaların kararlarını taşımaktadır.

1.A.1.4.2. Çoğunluk Oylaması

Çoğunluk oylaması sınıflandırma mantığının kullanıldığı zaman verilen kararlardan hangisinin takip edileceğini takip etmeyi sağlayacak olan karar verici mekanizmadır. Bu mekanizma sınıflandırma problemlerinin çıktılarında daha işe yarar bir konum sergileyebilir. Yapay zeka grupları içerisinde hangi karar daha çok veriliyorsa onu esas almak mantıklı olandır. Fakat sosyal ve mantıksal açıdan düşünüldüğünde bu karar en doğru karar olmayabilir. Bu sebepten dolayı da LSTM karar vericisinin sınıflandırma problemlerinde bundan daha iyi sonuç vermesi beklenmektedir. Bunun kesinlikle gerçekleşebilmesi için ek olarak bazı farklı yapıda düşünebilen yapay zekaların bulunması mantıklı olandır. Bu karar verici mekanizma doğrudan değerin tahmin edilme noktasında iyi olmayacağından dolayı sonuçlarda yorumlanmamıştır.

1.A.1.4.3. Yapay Sinir Ağı ile oluşturulan karar verici mekanizma

Yapay sinir ağı oluşturulan bu karar verici mekanizma diğerlerinden farklı olarak yapay zekalardan gelen bilgileri incelemektedir. Yani bu modelin de LSTM karar verici mekanizması gibi ham veri ile doğrudan bir bağlantısı bulunmamaktadır. Yapay sinir ağı hafızasız bir ağ yapısına sahip olduğundan dolayı LSTM karar verici mekanizması kadar iyi çalışamayacaktır. Fakat doğru karar vermek her zaman karışık algoritmalar gerektirmeyebilir. Bundan dolayı yapay sinir ağı ile karar vermek mantıklı olabilir ama beklenen sonuçta yine LSTM karar vericisinin tüm skorları geçmesi beklenmektedir.

1.A.1.5. Sonuçlar ve Değerlendirilmesi

Tasarlanan modeller tüm verinin %70 ile eğitildikten sonra sistem gerçek bir analiz varmışçasına karar vermeye başlamaktadır. Oluşturulan kararlar karar verici mekanizmalara iletilmektedir. Bu iletim sırasında yeterli veriye ulaşılınca karar verici mekanizmalar çalışmaya başlamıştır ve sonuç vermeye başlamışlardır. Yani kalan %30 veri online olarak çalıştırılarak karar vericiler sayesinde daha iyi sonuç verecek hale getirilmeye çalışmıştır.
Bu eğitim esnasında tüm veriler tahmin(forecasting) olarak yapılmaktadır. Yani üretilen verilerin hepsi -100 ile 100 arasında gelmekte olan verilerdir. Sistem bu veriler beslenerek aynı şekilde bir tahmin verisi üretmektedir. Bu veriler en son artış ya azalış şeklinde bir sınıflandırma kararına dönüştürülmektedir ya da doğrudan bu şekilde tahmin edilmektedir. Bu ayırımlardan dolayı da değerlendirme kriterleri olarak üç tip yaklaşımda bulunulmaktadır:

- Doğruluk (accuracy)
- Ortalama karesel hata(Mean square error)
- Dinamik Zaman Eşleştirme Bükme(Dynamic time warping)

- Veriler arası korelasyonlar

Bu üç tip hatanın hesaplanma sebebi problemin sonucuna farklı açılardan bakmaya çalışmaktır. Sınıflandırma probleminde verinin bir sonraki gün ki durumu artacak ya da azalacak şeklinde sınıflandırılmıştır. Dolayısıyla ne kadar fazla eşleşme var ise o kadar doğruluk payı yüksek bir çalışma olmaktadır.
Ortalama karesel hata da ise tahmin edilen sinyal ile gerçek sinyal arasındaki fark miktarı önem taşımaktadır. Her bir fark karesi kadar cezalandırılarak bir değerlendirme puanı oluşmaktadır.
Dynamic time warping diğer iki yönteme göre daha karmaşık bir algoritmayı sahiptir. Diğer yöntemler o anki değerleri göz önüne alarak bir hesaplama yaparken dynamic time warping zamanın belirli parçalarındaki değişimleri göz önüne alarak sinyallerin birbirlerine benzerliklerine bakmaktadır. Bu yöntemlerin hepsinin temel amacı sinyallerin üzerindeki benzerlik miktarlarını ölçmektir.
Karar verici mekanizma sonuçları açıkladığında farklı tip hata türlerine bakmak karar verici mekanizmaların nasıl çalıştığı hakkında bilgi sunabilir. Bu yüzden dolayı farklı hata tipleri ve bunların sonuçları gözlemlenmiştir.
Bu yöntemlere ek olarak korelasyon hesaplanmıştır. Korelasyon iki sinyalin birbirlerine olan benzerliklerini yani benzer türden hareketler yapıp yapmadığını kontrol etmeye yarayan bir olasılık fonksiyonudur. Burada Spearman korelasyon formülü kullanılmıştır ve bu formül aşağıdaki gibidir:

$$r = \frac{\sum\left(X-\hat{X}\right)\sum\left(Y-\hat{Y}\right)}{\sqrt{\sum\left(X-\hat{X}\right)^2\sum\left(Y-\hat{Y}\right)^2}}$$

Tüm bu hesaplanan sonuçlar tablolar üzerinde birleştirilmiştir. Bunların yanında ek olaraktan elde edilmiş olan sinyaller çizdirilmiştir.

Tablo 1. MSE değerleri tüm agentlar ve orijinal veri arasında

	arima	rsiAgent	lineerReg	Mlpagent2	Mlpagent	LSTM decider	Mlp decider	Majority decider
Set 1	1148.189	1751.811	-	-	848.171	464.614	1143.898	-
Set 2	1148.189	-	-	-	795.793	522.375	1145.11	-
Set 3	-	1751.811	2040.724	-	-	499.33	1109.268	-
Set 4	-	-	2040.724	718.588	-	524.127	962.946	-
Set 5	-	-	2040.724	-	-	519.816	1033.181	-
Set 6	-	-	-	-	780.836	509.691	876.953	-
Set 7	-	1751.811	-	-	-	528.814	792.391	-
Set 8	-	-	-	713.672	-	535.201	701.425	-
Set 9	1148.189	-	-	-	-	511.334	1147.886	-
Set 10	1148.189	1751.811	2040.724	721.443	835.902	522.082	1144.496	-

Tablo 2. Kesinlik değerleri tüm agentlar ve orijinal veri arasında

	Arima	Rsi	lineerReg	Mlpagent2	Mlpagent	LSTM decider	Mlp decider	Majority decider
Set 1	0.614	0.31	-	-	0.645	0.795	0.62	0.582
Set 2	0.614	-	-	-	0.682	0.761	0.611	0.642
Set 3	-	0.31	0.654	-	-	0.777	0.62	0.499
Set 4	-	-	0.654	0.717	-	0.801	0.654	0.703
Set 5	-	-	0.654	-	-	0.798	0.653	0.654
Set 6	-	-	-	-	0.722	0.811	0.719	0.722
Set 7	-	0.31	-	-	-	0.751	0.533	0.313
Set 8	-	-	-	0.717	-	0.779	0.714	0.717
Set 9	0.614	-	-	-	-	0.788	0.617	0.614
Set 10	0.614	0.31	0.654	0.718	0.72	0.788	0.616	0.642

Tablo 3. :DTW(dynamic time warping) değerleri tüm agentlar ve lstm arasında

	Arima	Rsi	lineerReg	Mlpagent2	Mlpagent	LSTM decider	Mlp decider	Majority decider
Set 1	2478.763	10681.917	-	-	14691.278	8895.867	2498.265	-
Set 2	2478.763	-	-	-	8584.998	7753.545	1889.886	-
Set 3	-	10681.917	10683.687	-	-	10990.965	5898.168	-
Set 4	-	-	10683.687	12774.266	-	9663.134	5442.051	-
Set 5	-	-	10683.687	-	-	8474.649	6157.878	-
Set 6	-	-	-	-	5924.447	5475.829	5875.65	-
Set 7	-	10681.917	-	-	-	9666.174	12464.061	-
Set 8	2478.763	-	-	-	-	9279.544	2497.789	-
Set 9	2478.763	10681.917	10683.687	11494.308	12651.954	9585.839	2548.258	-
Set 10	735	-	358	-	1059	-	730	-

Tablo 4. :MSE değerleri lstm decider ve tüm agentlar arası

	Arima	Rsi	lineerReg	Mlpagent2	Mlpagent	LSTM decider	Mlp decider	Majority decider
Set 1	735.374	1059.678	-	-	358.808	0	730.618	-
Set 2	783.564	-	-	-	412.492	-	780.104	-
Set 3	-	998.778	1702.879	-	-	-	668.466	-
Set 4	-	-	1794.146	309.937	-	-	600.719	-
Set 5	-	-	1642.591	-	-	-	561.457	-
Set 6	-	-	--	-	332.378	-	461.983	-
Set 7	--	969.929		-	-	-	214.681	-
Set 8	-	-	-	270.119	-	-	239.911	-
Set 9	742.23	-	-	-	-	-	741.702	-
Set 10	783.819	1060.289	1782.366	331.148	338.591	-	780.473	-

Tablo 5. Kesinlik değerleri lstm decider ve tüm agentlar arası

	Arima	Rsi	lineerReg	Mlpagent2	Mlpagent	LSTM decider	Mlp decider	Majority decider
Set 1	0.696	0.31	-	-	0.749	-	0.697	0.668
Set 2	0.678	-	-	-	0.72	-	0.674	0.723
Set 3	-	0.326	0.737	-	-	-	0.708	0.596
Set 4	-	-	0.714	0.826	-	-	0.724	0.815
Set 5	-	-	0.763	-	-	-	0.763	0.763
Set 6	-	-	-	-	0.744	-	0.742	0.744
Set 7	-	0.273	-	-	-	-	0.62	0.277
Set 8	-	-	-	0.785	-	-	0.782	0.785
Set 9	0.702	-	-	-	-	-	0.715	0.702
Set 10	0.691	0.335	0.717	0.801	0.745	-	0.682	0.715

Tablo 6. Dtw değerleri lstm decider ve tüm agentlar arası

	Arima	Rsi	lineerReg	Mlpagent2	Mlpagent	LSTM decider	Mlp decider	Majority decider

Set 1	10431.092	8047.015	-	-	9587.097	-	10496.962	-
Set 2	9377.533	-	-	-	6861.724	-	9384.037	-
Set 3	-	8100.846	18325.626	-	-	-	11296.571	-
Set 4	-	-	17586.017	8548.604	-	-	10544.178	-
Set 5	-	-	20148.808	-	-	-	10076.923	-
Set 6	-	--	-	3661.161	-	-	4517.449	-
Set 7	-	9124.822	-	-	-	-	7393.498	-
Set 8	-	-	-	6168.804	-	-	7714.366	-
Set 9	8596.264	-	-	-	-	-	8583.199	-
Set 10	9285.807	8079.099	17300.765	7440.057	10428.975	-	9202.496	-

Tablo 7. Korelasyon değerleri lstm decider ve tüm agentlar arası

	Arima	Rsi	lineerReg	Mlpagent2	Mlpagent	LSTM decider	Mlp decider	Majority decider
Set 1	0.32	-0.652	-	-	0.327	-	0.32	0.144
Set 2	0.272	-	-	-	0.228	-	0.272	0.223
Set 3	-	-0.59	0.423	-	-	-	0.377	-0.034
Set 4	-	-	0.356	0.436	-	-	0.372	0.43
Set 5	-	-	0.483	-	-	-	0.48	0.491
Set 6	-	-	-	-	0.276	-	0.266	0.439
Set 7	-	-0.642	-	-	-	-	-0.115	-0.522
Set 8	-	-	0.442	-	-	-	0.446	0.535
Set 9	0.315	-	-	-	-	-	0.314	0.236
Set 10	0.28	-0.593	0.363	0.45	0.301	-	0.279	0.316

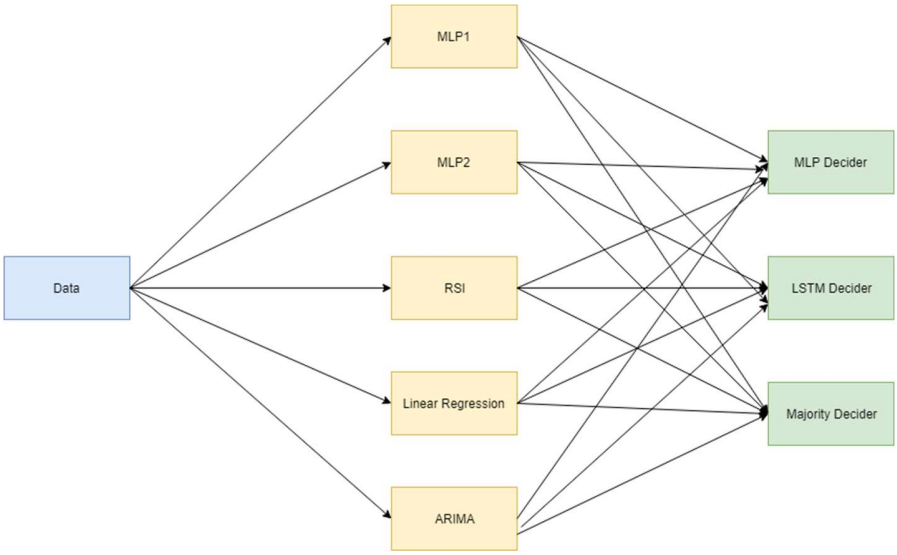

Şekil 4. Genel olarak tasarlanan modellerin birleştirilmiş hali olan ağ

1.A.2. IP1 ve IP2 Çalışmaları (Alperen&Ömer)

Bu iş paketinde trend ve değer tahmini için zaman serisi tabanlı verilere bağlı teknik gösterge modelinin tanımlanması ile ilgili çalışmalar ve evrimsel optimizasyon ile bu teknik gösterge modelinin geliştirilmesi aktiviteleri bulunmaktadır. Bu konular ile ilgili çalışmalar önceki dönemde başlamış olduğundan önceki gelişme raporlarında konu ile ilgili literatür taraması verilmiştir. Evolutionary optimized stock market support-resistance line detection for algorithmic trading systems Eşref Oğuzhan Yıldırım, Mustafa Uçar, Murat Özbayoğlu)

Bu dönemde teknik gösterge modeli üzerinde durduk. Bu teknik gösterge modelimiz piyasa tahmini yapılırken büyük oranda kullanılan destek ve direnç çizgileridir. Bu konudaki çalışmalarımıza devam etmeyi planlıyoruz.

Bu iş paketlerinde gerçekleştirilen faaliyetler konu bazlı incelendiğinde aşağıdaki başlık ön plana çıkmaktadır.

- 2 yıllık hisse senedi grafiği ve verileri kullanılarak destek ve direnç çizgilerinin belirlenmesi

1.A.2.1. 2 yıllık hisse senedi verileri kullanılarak destek ve direnç çizgilerinin belirlenmesi

Bu çalışmada, hisse senedi ile ilişkili olarak son 2 yılın kapanış değerlerini içeren zaman dizisini kullanmaya karar verdik. Farklı hisse senedi değerleri için destek ve direnç çizgilerini matematiksel olarak elde etmeye çalıştık ve elde edilen elde edilen destek-direnç çizgileri, optimum al-sat noktalarını bulmada kullanılmıştır. Önerilen modelimiz, al ve tut modeli ile karşılaştırıldığında %10'luk bir getiri artışı gözlemlenmiştir. Elde edilen sonuçlar doğrultusunda, sistemimiz tarafından üretilen destek-direnç çizgilerimizin, al- sat noktalarını belirlemede bir indikatör olarak kullanılabileceğini göstermiştir. Ancak bu bir ön çalışmadır ve doğru bir karar verebilmek için daha birçok analize ihtiyaç vardır. Önerilen modelin farklı indikatörler ile birlikte kullanılmasıyla oluşturulacak bir ticaret modeli daha iyi sonuçlar verebilir.
Önerdiğimiz modelin genel çalışma şekli aşağıdaki şekilde gösterilmektedir.

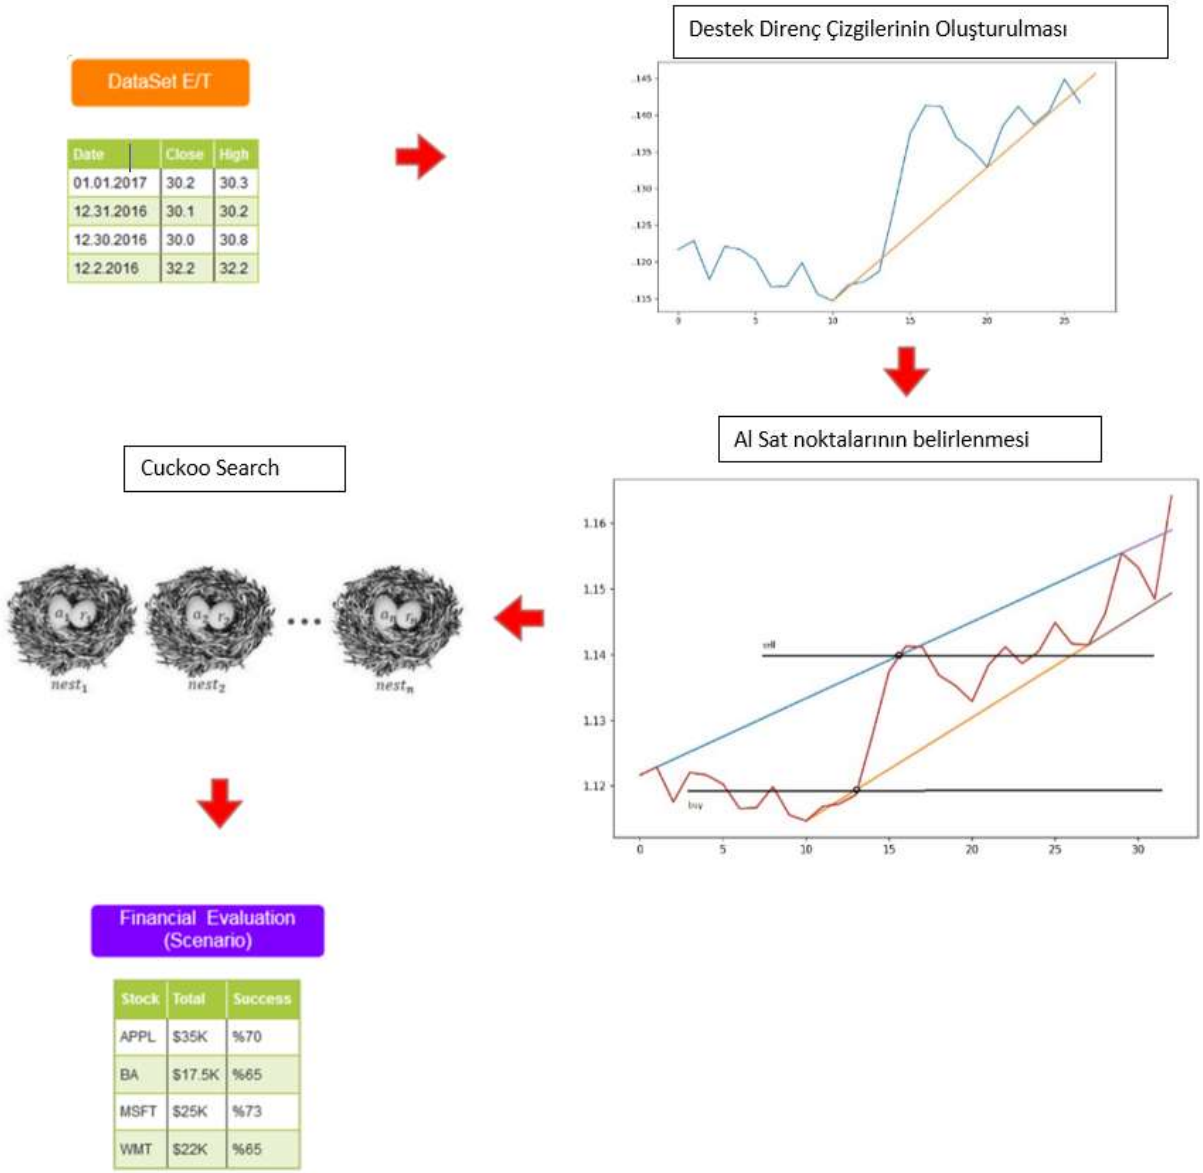

Şekil 5. Önerilen modelin aşamaları

Bu iş paketinde alım-satım modelimizin daha iyi bir sonuç vermesini sağlayabilecek bir teknik indikatör modeli oluşturmayı hedefledik.

Bu şekilde, hisse senedi verileri ile "Al", "Sat" ve "Tut" senaryolarını belirlemek için destek ve direnç çizgilerini kullanan bir yaklaşım önerilmiştir. Bu modelde hisse senedi verileri ile destek ve direnç çizgilerinin çizilmesi sağlanmaktadır. Bu çizilen destek ve direnç çizgileri, hisse senedi değerlerinin hangi aralıkta kalmasını beklediğimizi gösterir. Şekil 5de görülebileceği gibi yöntemimiz beş ana aşamaya ayrılmıştır. Veri setinin setinin elde edilmesi, veri setine uygun destek ve direnç çizgilerinin çekilmesi, al sat noktalarının belirlenerek ticaret yapılması ve genetik algoritma olan Cuckoo Search ile destek direnç çizgilerinin çizilmesinde kullanılar parameterelerin optimize edilmesi.

Destek ve direnç çizgilerinin çizdirilmesi aşamasında Tüm lokal maksimum ve minimum noktalarını kullanarak, destek-direnç çizgilerimizin, verilerimizi alttan ve üstten sıkıştıracak şekilde en iyi çizgiler olmasını istedik. İlerleyen günlerde, destek ve direnç çizgilerimizin hala kullanılabilir olup olmadıklarını inceledik. Destek direnç çizgilerimiz kullanılabilirliğini yitirdiğinde, yani destek çizgimizin altında veya direnç çizgimizin üstünde veri elde ettiğimizde, o güne en yakın olan yerel minimum veya yerel maksimum noktasını kullanarak destek veya direnç çizgimizi yeniden oluşturduk. Bu değiştirme işlemini yaparken aşağıdaki matematiksel ifadeleri kullandık. n herhangi bir noktanın indisini, i ve j'ler yerel maksimum noktalarının indislerini M eğimi ve Ɛ hata payını göstermek üzere, bu doğru üzerindeki bir noktanın büyüklük değerini

$$d_n = M_{i,j} * (x_n - x_j) + y_i$$

olarak gösterebiliriz.

$$|d_n - y_n| \leq y_n * \varepsilon \quad \forall n \in [i, j]$$

ifadesi sağlanacak şekilde

$$\max_{i,j}\left(\sum_{n=i}^{j}(|d_n - y_n| < y_n * \varepsilon)\right)$$

bulunarak çizgiler belirlenir. Örnek çizgiler Şekil 6'de verilmiştir. En iyi vektörün belirlenmesinde kullanılan bir diğer yöntem ise çizgi etrafında bir limit içinde maksimum sayıda yerel maksimum ya da yerel minimum bulundurmasıdır. Eğer bu sayılar eşitse daha uzun olan vektör daha iyi kabul edilmektedir. Ancak bu yöntem kural bazlıdır ve her koşulda doğru kararı verememektedir. İlerleyen süreçte parametrelerini sürekli optimize ederek ilerleyen bir sistem kurmayı va daha iyi çizgiler çekmeyi planlamaktayız.

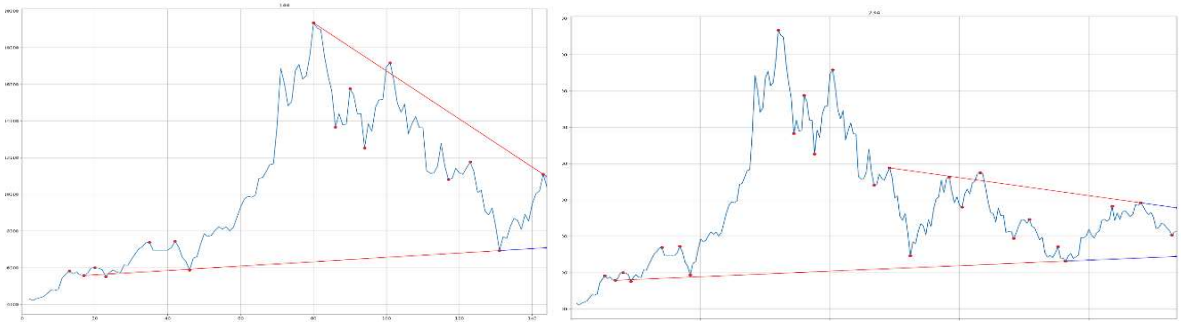

Şekil 6. Destek ve direnç çizgileri

Bu çalışmanın al sat noktalarını bulurken, değeri destek-direnç çizgilerine belirli bir oranda yaklaşan noktaların trendlerini inceledik. Destek çizgimize yaklaşmış olan nokta artış eğiliminde bulunuyorsa ya da direnç çizgimizi kırmış ise bu nokta bir al noktasıdır. Aynı şekilde direnç çizgimize yaklaşmış olup azalma eğilimi gösteren ya da destek çizgimizi kırıp azalma eğilimi gösteren nokta sat noktasıdır. Burada noktaların çizgilerimize yaklaşma durumunu optimize edilecek bir parametre ile incelemekteyiz. Ek olarak buy and hold da negatif sonuca sahip olan hisseler için açığa satma (short sell) algoritmasını da ekledik. Düşüşe geçen trendlerde kar sağladığını gördük. Bu sistemde de trendi belirlemek için daha iyi indiaktörler kullanarak daha kesin kararlar vermeyi planlıyoruz.

Şekil 7. Al ve sat noktaları

Çalışmamızın optimizasyon kısmında modelimizdeki parametrelerimizi optimize etmek için, evrimsel optimizasyon algoritması olan Cuckoo Search algoritmasını kullandık. Bu algoritmaya, destek ve direnç çizgilerimizin tolerans oranları ile al-sat günlerinin bulunmasındaki yakınlık oranlarını optimize edilecek parametreler olarak verdik. Cuckoo Search Algoritmasındaki strateji 3 temel adım kullanarak optimizasyon uygular:

1) Her bir guguk kuşu, bir seferde koordinatlarını temsil eden bir çözüm kümesine yumurta bırakır ve aynı zamanda rastgele seçilmiş bir yuvaya bu yumurtayı atar.
2) Yüksek kaliteli yumurta içeren yuvaların bir kısmı (en iyi çözümler), bir sonraki kuşağa taşınacaktır.
3) Yuva sayısı sabittir ve ev sahibi kuş tarafından guguk kuşu yumurtası veya yuvanın keşfedilmesi, elenmesi ve başka bir bölgede tamamen yeni bir yuva inşa edilmesi olasılığı p(0,1)'dir.

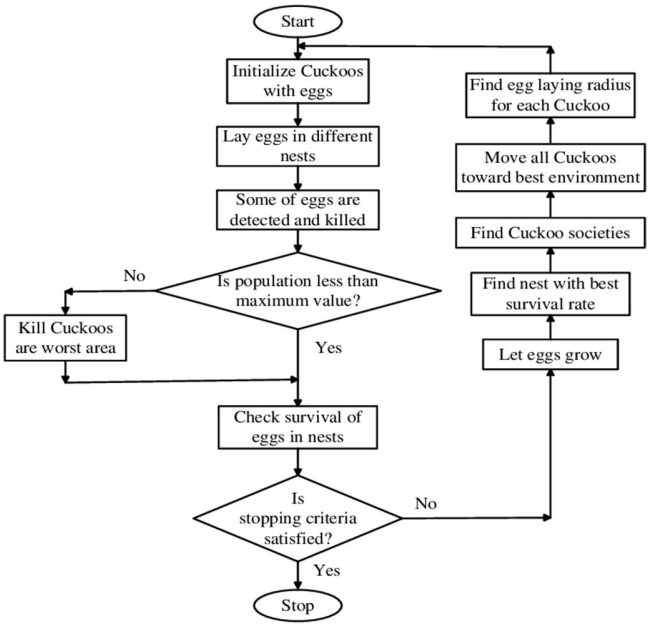

Şekil 8. Kullanılan Cuckoo Search Algoritması

Çalışmamızın farklı piyasa koşullarını temsil etmesi için 9 farklı veri seti seçilmiştir. Her veri seti 2 senelik verilerden oluşmaktadır. Aşağıdaki paramaetrelere göre değişik veriler alınmıştır

- Getiri miktarı (OUR)
- Yıllık al-sat miktarı (ANT)
- Başarı miktarı (POS)
- Maximum al-sat getirisi
- Minimum al-sat kaybı
- Maksimum kapital
- Minimum kapital
- İç getiri oranı (ROI)

Sistemimizin bazı durumlarda başarılı olduğu görülmektedir ancak bu sonuçlar optimize edilmemiş sonuçlardır. Optimizasyon uygulandıktan sonra daha iyi sonuçlar alınması beklenmektedir.

Tablo 8. Evaluation of Proposal with different stock datas

name	our	bah	our_r	bah_r	ant	pos	apt	l	mpt	mlt	maxc	minc
aapl	8162.76	7217.43	-21.8849	-32.749	48.6667	35	-46.0632	4.85	7.64373	-10.1782	10078.3	7771.05
amd	7183.3	5195.69	-33.1357	-54.915	54.75	28.8889	-48.8255	3.44444	25.5666	-20.9964	12001.3	5078.98
btc	6764.97	3890.98	-37.843	-68.2869	40.15	51.5152	-73.1917	6.51515	14.9886	-25.5382	10000	4806.7
csco	7735.76	7001.54	-26.8279	-35.1885	34.0667	35.7143	-82.8462	7.82143	7.09578	-13.4487	10898.8	7529.32
euro	9907.06	9936.39	-1.12958	-0.773391	35.2833	27.5862	-3.21634	3.48276	0.21086	-0.193793	10005.8	9907.06
ixic	11484.5	11793.3	18.3414	22.2238	34.0667	60.7143	51.372	8.10714	4.40742	-4.61965	11820.9	9651.5
rut	10627.4	10878.2	7.68469	10.7836	25.55	38.0952	35.5458	11	9.74694	-7.22864	11775.5	9996.21
spy	10466	11176.2	5.69768	14.4876	53.5333	52.2727	11.9186	4.79545	2.86454	-8.0607	11112.5	10000
tsla	16177.7	12130.9	79.548	26.4937	30.4167	48	234.151	8.24	23.1895	-18.4817	16414.8	10000

1.A.3. IP7 Çalışmaları (Efe)

Bu iş paketinde opsiyon fiytlama ve oynaklık tahmini ele alınmıştır. Temel hedef olarak opsiyon fiyatlamasında sıklıkla kullanılan Black-Scholes (BS) opsiyon fiyatlama modelinin üzerine çıkılması planlanmıştır. Bu yaklaşımla öncelikli olarak BS hakkında bilgi verilecek ve kronik sorunları ile günümüzdeki opsiyon fiyatlama yaklaşımlarından bahsedilecek, daha sonra ise çalışma için kullanılan veri seti ve geliştirilen modeller başarım kıyaslamaları model analizleri ile birlikte yer alacaktır.

Black-Scholes [1], Fischer Black ve Myron Scholes tarafından kurulan bir modeldir ve bazı ayarlamalar [2] ile opsiyon fiyatlarında en sık kullanılan formül olmuştur. Formülün tanıtımıyla, opsiyon alım satım işlemlerinde ciddi bir arttış olmuştur [3]. Uçuculuk gülüşü gibi bilinen bazı sorunlar olsa da, genel olarak model, fiyatlandırma ve finansal sektör tarafında iyi bir yaklaşıma sahiptir [2].

Öte yandan, BS formülü çıktısında, özellikle opsiyon primi değer eğrisinin her iki ucunda, fiili opsiyon fiyatlarıyla hafif farklılıklar göze çarpmaktadır. Ayrıca, hacme bağlı olarak, gerçek zamanlı fiyatlandırmada önemli farklılıklar ortaya çıkabilmektedir. Gittikçe daha fazla sayıda insan çevrimiçi ticaret hesapları açmaya başladığından ve elektronik ticaretle uğraştığından, daha iyi opsiyon fiyatlandırması bir zorunluluk haline gelmiştir. BS için daha doğru bir opsiyon fiyatlandırma modeli bulmak ve belirsiz volatilite tanımları olmadan daha gerçekçi sonuçlar elde etmek temel motivasyonumuzdur.

Çalışmada, odak noktamız yapay sinir ağı (YSA) temelli yaklaşımlar kullanarak Avrupa tipi opsiyon ticareti için BS (Black-Scholes) modelinden daha iyi bir performans sergilemektir. Anlatımın yapısı şu şekildedir: Bu kısa tanıtımdan sonra, bu alandaki ilgili çalışmalar analiz edilecek, sonuçları ile birlikte kullanılan metodolojiler açıklanacak ve son olarak gelecekteki çalışmalar ve sonuçlar verilecektir.
BS modeli en yaygın kullanılan opsiyon fiyatlama modelidir. Formülasyon son birkaç on yılda derinlemesine analiz edilmişve bazı durumlarda kronik problemleri gözlenmiştir. Örneğin, [1] 'da, oldukça değişken piyasalarda BS tahmininin opsiyon fiyatının gerçek değerini aştığı sonucuna varılmıştır. [4], BS hatasının kazançta ve kezanç dışında arttığını göstermektedir. Ayrıca, [5], bir opsiyonun BS ile gerçek değer arasındaki farkın, sona erme süresinin artmasıyla arttığını belirtmiştir.

Bilişim teknolojilerindeki son gelişmeler ile AI (Yapay Zeka), uygulamalı çalışmaların hemen hemen tüm alanlarında daha fazla önem kazanmaktadır. Finansal alan da bir istisna değildir. [6] gibi araştırmalar, parametrik modeller yerine, parametrik olmayan AI tabanlı modellerle yapılan hesaplamaların daha iyi sonuçlar verebileceğini göstermektedir. Takip eden bölümde, yapay zeka temelli yaklaşımlara ağırlık verilerek, opsiyon fiyatlama konusundaki son çalışmalar gözden geçirilecektir.

Temel olarak, zımni volatilite opsiyon fiyatlamasında çok önemli bir rol oynamaktadır. Birçok farklı yöntem önerilmesine karşın hiçbiri volatilitenin tam olarak neye dayandığına açıklama getirememiştir. BS hesaplamasının oynaklık teriminde de aynı belirsizlik mevcuttur. Gerçek oynaklık ancak opsiyonel alım satımın gerçekleştirilmesinden sonra BS formülünden geri elde edilebilir. Bunun dışında, çoğu durumda volatilite bilinmemektedir, ancak değerinin tahmininde iyi yaklaşımlar vardır. Bu bakış açısıyla, çalışmalar 2 ana yaklaşım olarak gruplandırılabilir, birincisi volatilite bulmayı, ardından opsiyon fiyatını hedeflemeyi ve ikincisi opsiyon fiyatlarının doğrudan hesaplanmasına odaklanır.

Oynaklık tarafında, GARCH (Genelleştirilmiş Otoregressif Koşullu Heteroskedastisite) modeli, en saf haliyle tahmin edilebilecek kadar iyi olmamasına rağmen farklı değişkenlerle popülerdir [7]. Örneğin, [8] 'de, ANN (Yapay Sinir Ağı) ile entegre GARCH kullanılmış ve uçuculuk tahmininde iyileşme sağlanmıştır. [9]'da, HMM (Saklı Markov Modeli), GARCH ile birlikte BS modelinde opsiyon fiyatlandırmasının volatilitesini tahmin etmek için kullanılmıştır ve GARCH'ın volatilite üzerinde fazla tahminde bulunması önlenmiştir. [10]'da, BS'nin gelecekteki volatilitesi, YSA aracılığıyla geçmiş volatiliteler kullanılarak tahmin edilmektedir. Ayrıca, [11]'de, ANN kullanan volatilite hesabı ile varlık tahsis etme kabiliyetinin arttırıldığı gösterilmiştir. [12]'de, test için S&P 500 opsiyonları kullanılmış, oynaklık, makul bir başlangıç noktası verilmesi ile regresyon ağacı bazlı algoritma yardımıyla hesaplnmış ve performansın arttıpı gözlenmiştir.

Opsiyon fiyatının doğrudan hesaplanması tarafında ise, [13]'de, [6] öngörü modelinde var olanlara ek olarak, hacim ve faiz oranı gibi öznitelikler kullanan RBF (Radyal Temel Fonksiyon) tabanlı bir yaklaşımda bulunulmuştur. [14]'da BT (Binom Ağacı), FD (Sonlu Fark) ve MC (Monte Carlo) opsiyon fiyatlandırma tahminleri, Hong Kong opsiyon pazarında ANN ve SVR (Destek Vektör Regresyon) kullanılarak geliştirilmiştir. [15]'de İsveçli alım opsiyonlarında YSA kullanılmış ve YSA ile fiyatlandırmanın parametrik BS hesaplamalarından daha iyi olduğu görülmüştür. [16]'da, ANN'nin nispeten yüksek risklerle daha yüksek getiri hedefleyen yatırımcıların tercihi olan değişken piyasalarda daha iyi performans gösterdiği ve BS'nin daha güvenli uygulamalarda daha uygun olduğu sonucuna varılmıştır. [17]'de, YSA'nın alım opsiyonlarında satıma göre daha iyi bir performansa sahip olduğu belirtilmiştir. [18], MNN (Modüler

Sinir Ağları) 'nda S&P-500 Avrupa alım opsiyonlarını kullanmış ve standart ileri beslemeli sinir ağlarının modülerlikle geliştiği sonucuna varmıştır. [19]'da, NN (Yapay Sinir Ağı) yaklaşımlarının, eğitimde oldukça yavaş olmasına rağmen, opsiyon fiyatlandırması için uygun olduğu görülmüş, YSA (Çok Katmanlı Perceptron)'nin, RBF tabanlı NN tasarımlarına kıyasla daha iyi sonuçlar verdiği belirtilmiştir. [20]'da, faiz oranı, oynaklık ve hisse fiyatı bulanık desenler olarak gösterilmiş ve Avrupa tipi opsiyon fiyatları bulanık sayılara dönüştürülmüştür. [21]'da, İleribeslemeli Sinir Ağları'nın (FNN), stokastik oynaklık (SV) ve stokastik oynaklık rasgele atlama (SVJ) ile karşılaştırıldığında opsiyon fiyatlarında iyi sonuçlar verdiği sonucuna varılmıştır.

Çalışmamızda, S& P 500 ETF (SPY hisse kodu) için Şubat 2010 ile Kasım 2010 arasındaki opsiyon verileri kullanılmıştır. S& P en yüksek seçenek hacmi ve çeşitliliğine sahip en büyük ETF'dir. Veri kümesi alt örneği, Tablo 9'de verilmiştir. Tabloda, gerekli tüm bilgiler bazı BS iterasyonları kullanılarak bilinen opsiyon fiyatından hesaplanan zımni volatilite ('IV') ile birlikte verilmektedir.

Hisse Fiyatı	Tipi	Bozulma Günü	Veri Günü	İşlem Fiyatı	Alış	Satış	Volüm	Talep	Heaplanmış Uçuculuk
111.41	alış	25/06/2010	21/06/2010	112.0	0.82	0.85	2024	3271	0.2403
112.392	satı¸s	21/08/2010	06/08/2010	88.0	0.01	0.03	122	7866	0.5085
116.73	alış	22/10/2010	19/10/2010	120	0.05	0.06	6182	24927	0.2269

Tablo 9 Ham veriseti

Opsiyon fiyatlandırması için veri hazırlığı sırasında, gerçek ve BS bazlı opsiyon fiyatları Yahoo finansmanı aracılığıyla çıkarılan verilerden hesaplanmaktadır. Ek olarak, BS performansı bu fiyat değerleri kullanılarak hesaplanır.

İlk adım olarak, işlemleri basitleştirmek adına opsiyonların alış ve satış fiyatlarının ortalamasını alıp "Opsiyon Fiyatı" sütunu adıyla opsiyonun gerçek fiyatı olarak belirledik. Ayrıca, çalışmada sadece sıfır hacimli olmayan alım satım opsiyonları göz önünde bulundurulmuştur, keza yeterli hacme sahip olmadan, alış veya satış fiyatları güvenilir olmayabilir. Analizimize belirli bir seçeneği dahil edip etmemeye karar vermek için bir hacim eşik değeri tanımladık. Seçeneklerin çoğu hiçbir zaman alınıp satılmadığından, bu eşik değeri 1 olarak seçilmiştir. Bu eşik seviyesinin seçilmesiyle verilerin % 70'i silinmiştir (0 hacme sahip opsiyonlar). İlginçtir ki, hacmi olmayan opsiyonlar, yani işlem görmeyenler, işlem görmüş olanlardan daha iyi BS tahminlerine sahiptir (Şekil 10). Ancak bir opsiyon işleme girdiyse, BS hatası Şekil 9'de gösterildiği gibi davranmaya başlamaktadır. Bu, opsiyon ticaretçilerinin yalnızca BS bağlı olmayabileceğini göstermektedir. Şekil 9'a kısa bir bakılırsa, histogramın 0 civarında zirve yaptığı görülür, bu da BS tahminlerinin genel olarak iyi sonuç verdiğini anlatmaktadır.

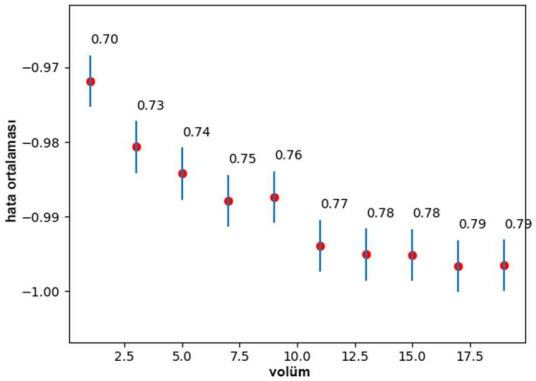

Şekil 9. Volüm alt sınırına göre hata ortalaması (volüm, alt volüm eşiğidir, hata ortalaması ekseni, eşik değerinden daha küçük volümlü opsiyonların BS hatası ortalamasıdır, çizgiler eşik değerinden düşük völümlü opsiyonlara sahip BS hata varyansıdır, tüm veriler arasında eşik değerden daha düşük volümlü olan opsiyonların oranı her noktanın sağ üst kısmına yazılmıştır)

Daha sonra, hem alım hem de satım türleri için Black-Scholes Avrupa tarzı seçenek fiyatları hesaplandı. Hesaplamalar için, zımni volatilite değeri, opsiyon süresinin sona ermesi için kalan gün sayısı ile birlikte gerekmektedir. İşlem tarihine olan gün sayısı, 'Veri Günü' ile 'Bozulma Günü' tarihleri arasında kalan gün sayısı ile hesaplanıp 'İşleme

Kalan Gün' sütunu oluşturulmuştur. Oynaklık için, bir aylık süreyle (20 iş günü) saf gün içi hisse senedi artışı alınmış daha sonra da bir yıllığa çevrilmiş ve bu değerler de 'Uçuculuk' sütununa yerleştirilmiştir. BS hesaplamaları için, alım ve satımda sırasıyla (1) ve (2) kullanılır. d_1, d_2 sırasıyla (3) ve (4) denklemleriyle hesaplanır. Bu denklemlerdeki $N(d_1)$ ve $N(d_2)$ normal Gauss dağılımının d_1, d_2 değerlerinde kümülatifidir. Kullanılan parametrelerin açıklamaları Tablo 10 BS formülünde kullanılan parametreler [22] verilmiştir. BS hesaplamaları için risksiz oran 3 aylık hazine bonosu iadesi olarak seçilmiştir. Bu belirli bir süre boyunca tüm günler için 0.0625 olarak alınmıştır. Ayrıca, bu formülasyonlar şunları varsaymaktadır;

- işlem maliyeti yok,
- opsiyonun erken işlemi yasak (Avrupa tarzı belirtildiği gibi)
- faiz oranları sabit,
- Şirketlerin risk değerleri bilinmekte ve sabit,
- temettüler hariç.

$$C = S\,N(d_1) - Xe^{-rt}N(d_2) \qquad 1$$

$$C = Xe^{-rt}N(-d_2) - S\,N(-d_1) \qquad 2$$

$$d_1 = (\ln\left(\frac{S}{X}\right) + \left(r + \frac{\sigma^2}{2}\right)T)/(\sigma\sqrt{T}) \qquad 3$$

$$d_2 = (\ln\left(\frac{S}{X}\right) - \left(r + \frac{\sigma^2}{2}\right)T)/(\sigma\sqrt{T}) \qquad 4$$

Parametre	Açıklama
C	Opsiyon Fiyatı
S	Hisse Fiyatı
X	İşlem Fiyatı
R	Risksiz Faiz Oranı
T	İşleme Kalan Gün

Tablo 10 BS formülünde kullanılan parametreler

Hesaplamalardan sonra, veri seti, Tablo 11'de belirtilen formata revize edilmiş ve BS formülü ile hesaplanan opsiyon fiyatı 'BS Opsiyon Fiyatı' olarak eklenmiştir.

Hisse Fiyatı	Tipi	İşleme Kalan Gün	İşlem Fiyatı	Opsiyon Fiyatı	Volüm	Talep	Hesaplanmış Uçuculuk	Uçuculuk	BS Opsiyon Fiyatı
111.41	alış	25/06/2010	112.0	0.82	2024	3271	0.2403	0.2655	0.9983
112.39	satı,	21/08/201	88.0	0.0	122	7866	0.5085	0.1533	7.65e-

2	s	0		1					12
116.73	alış	22/10/2010	120	0.05	6182	24927	0.2269	0.1242	0.003

Tablo 11. Revize edilmiş veri seti

Reel ve BS opsiyon fiyatları kullanılarak, BS hatası (BS opsiyon fiyatı) - (gerçek opsiyon fiyatı) olarak hesaplanmış ve Şekil 9 histogramı oluşturulmuştur. BS opsiyon fiyatlandırmasının hata ortalaması -0.953 ve varyansı 9.731'dir. BS hatasında, gerçek değerlerinin BS hesaplamalarından biraz daha yüksek olduğu görülmektedir. Bu, tüccarların beklentilerinden kaynaklanıyor olabilir. Güvende olmak için, opsiyonlar nispeten daha yüksek fiyatlandırılıyor veya hesaplamalarda başka bazı oynaklık hesaplamaları veya alternatif opsiyon fiyatlandırma yöntemleri uygulanıyor olabilir.

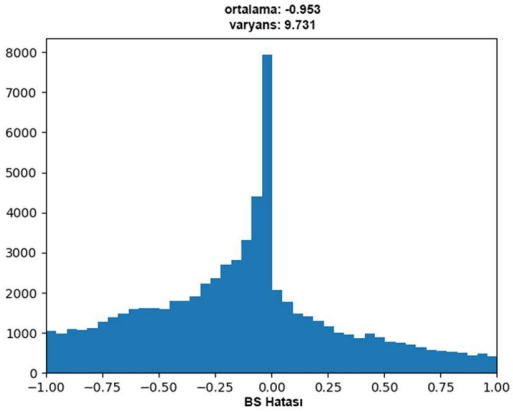

Şekil 10. BS hata histogramı

Yapılan bu ön hazırlıklardan sonra opsiyonel fiyat tahmini için 1 tek aşamalı ve 4 çok aşamalı olmak üzere 5 farklı statik, YSA temelli yaklaşım oluşturulmuş ve karşılaştırılmıştır. Daha sonra en iyi tasarım, dinamik modüler tasarıma dönüştürülerek doğrusal optimizasyon algoritması kullanılarak optimize edilmiştir. Bu modellerin detayları alt başlıklarda verilmiştir.

Model geliştirme ve performans analizi sırasında, BS hesaplamasından sonra veriler (05.2009 - 09.2009 arası) günlük olarak \% 80 eğitim ve \% 20 test olmak üzere iki bölüme ayrılmıştır.

Tüm yapılarda, öznitelikler Tablo 12'de gösterildiği gibi seçilmiştir ve aynı eğitim, test ve doğrulama setleri kullanılmıştır. Bu öznitelikler temel olarak BS hesaplamasında kullanılan parametrelere ek işlem hacminin eklenmesiyle oluşturulmuştur. Bu nedenle, araştırmamız, zaman serisi bağımlı modelleri kullanmadan ön volatiliteye ve temel fiyat tahmin aşamalarına bağlı olmayan ve BS ile aynı parametreleri kullanan yaklaşımları amaçlamaktadır. Tabloda görüldüğü üzere, işem fiyatının kendisi yerine işlem fiyatı / hisse fiyatı oranı, hisse senedi fiyatı ile birlikte seçilmektedir. Opsiyon işlemlerinin çoğu, işlem fiyatının neredeyse hisse fiyatına eşit olduğu yerlerde uygulanmaktadır. Bu seçimle yapay sinir ağlarının hemen hemen aynı veri ile beslenmesinin önüne geçilmiştir.

Öznitelikler
Alış mı
Hisse fiyatı
İşleme kalan gün sayısı
Uçuculuk
Volüm
İşlem fiyatı / Hisse fiyatı
Risksiz faiz oranı
Opsiyon BS fiyatı

Tablo 12 Öznitelikler

Ayrıca, risksiz oran başka bir girdi olarak eklenmiştir. Daha önce açıklandığı gibi bu değer tüm veriler için sabittir (ancak daha uzun veri seti süreleri için değiştirilebilir). Ek olarak, tüm modellerin borsa kapanış saatlerinde kullanılmak üzere tasarlandığını varsaydığımızdan, hacim ve hisse bilgileri de eklenmiştir.

Tüm modellerde, z dönüşümü ile normalizasyon yapılmış eğitim süreçlerine girdiler normal verilerle iletilmiştir. Gerçek opsiyon fiyat değerleri olarak çıktılar olduğu gibi tutulmuştur. Bu normalize edilmemiş çıktılarla eşleştirmek için, aktivasyon fonksiyonu identitiy fonksiyonu olarak belirlenmiştir.

Tüm modeller 25 farklı doğrulama setiyle çalıştırılmıştır. Her bir uygulamada opsiyon fiyatlandırma hatası ortalaması ve varyansı, Şekil 11 'de işaretlenmiştir. Uygulamaların MSE istatistikleri Tablo 13'de verilmiştir. Bu nedenle, makale boyunca Şekil 11 ve Tablo 13'e referans verilecektir.

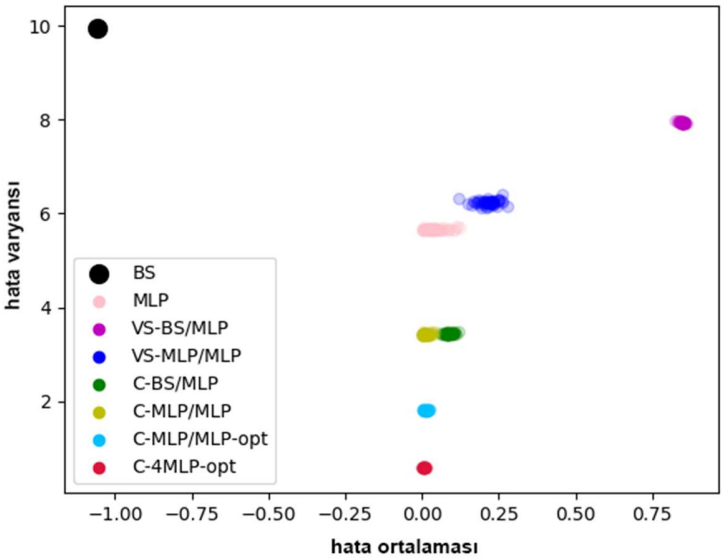

Şekil 11. BS ve modellerin ortalama hata ve hata varyansı (her biri 25 farklı doğrulama için)

	BS	MLP	VS-BS/MLP	VS-MLP/MLP	C-BS/MLP	C-MLP/MLP	C-MLP/MLP-opt	C-4MLP-opt
En iyi	10.9518	5.6407	8.6370	6.1291	3.4209	3.4001	1.80271	0.59600
En kötü	10.9518	5.7690	8.7017	6.4618	3.5288	3.4937	1.82464	0.60441
Ortalama	10.9518	5.6699	8.6529	6.2906	3.4515	3.4293	1.81234	0.59810
Varyans	0	0.0003	0.0001	0.0032	0.0002	0.0003	0.00003	0.000003

Tablo 13 Ortalama karesel hatalar (25 farklı setle elde edilen skorların en iyi ve en kötü değerleri ile bu sonuçların ortalaması ve varyansı)

1.A.3.1. Tek Aşamalı YSA

İlk modelimizde, en basit yaklaşım olarak, YSA kullanılmıştır. Eğitilen model test verileri kullanılarak doğrulanmış ve opsiyon fiyatları buna göre hesaplanmıştır. Sistem 25 farklı doğrulama seti ile çalıştırılmış ve her döngünün hata ortalaması ve varyansı Şekil 11'te YSA etiketiyle işaretlenmiştir. 25 uygulama için ortalamanın (ortalama, varyans) çifti (0.03881, 0.00115) ve varyansın (ortalama, varyans) çifti (5.66692, 0.00043) olarak elde edilmiştir.

1.A.3.2. Çok Aşamalı YSA

Daha iyi sonuçlar elde etmek için, VS-BS / MLP, VS-2MLP, C-BS / MLP, C-2MLP olarak 4 farklı çok kademeli YSA bazlı model önerilmiştir. Adlandırmada, birinci bölüm, sınıflandırma yöntemi olarak yapının ilk adımın VS uçuculuk

gülümsemesi yaklaşımına göre sınıflandırıldığını ve C NN esaslı sınıflandırıcı kullanıldığını açıklar. '-' işaretinden sonraki ikinci bölüm, birinci aşamadaki sınıflandırılmış bölümlerin hangi yapıya iletildiğini gösterir. BS, birinci aşamada sınıflandırılan seçeneklerin bir kısmının BS formülasyonu kullanılarak hesaplandığı ve YSA, sınıflandırılan kısmın öngörülen fiyatı almak için YSA'ye beslendiği anlamına gelir. Bu şekilde, kaskadlı adlandırma ile, örneğin C-BS / MLP, opsiyonların ilk olarak bir sınıflandırıcı ile sınıflandırıldığı ve opsiyon fiyat belirlemesi için ikinci aşamada opsiyonların bir kısmının BS ile diğer bir kısmının ise YSA ile hesaplandığını gösterir. Bu durumda, sınıflandırıcı verileri 2 ayrı gruba dağıtır. Başka bir örnek olarak, C-MLP / MLP (veya C-2MLP, ikinci aşama olarak farklı YSA kullanım sayısı kendisine eklenmiş bir sayı ile belirtilir), verilerin YSA sınıflandırıcı ile sınıflandırıldığı ve 2 gruba yayıldığı bir yapıdır. Opsiyonel fiyatları hesaplamak için ikinci aşamada her bir grubun kendi YSA regresörleri vardır. Daha sonra, C-MLP / MLP optimize edilmiş ve C-MLP / MLP-opt olarak adlandırılmıştır ve modülü ikinci aşamada YSA regresörlerini kullanacak şekilde geliştirmek için modüler bir yapıya dönüştürülmüş, böylece birinci aşamada sınıflandırılmış gruplar artırılarak C-3MLP (veya C-MLP / MLP / MLP) veya C-4MLP oluşturulmuştur. -opt uzantıları tasarımların en iyileştirildiğini gösterir.

1.A.3.2.1. VS-BS/MLP

BS modeli ile ilgili yapılan bazı önceki çalışmalara göre [4],parasallık sınır çizgisinden (hisse fiyatı/işlem fiyatı değerinin =1 olduğu nokta) uzaklaşıldıkça (fiyat dağılımı eğrisinin kuyrukları) fiyatlama hatasının arttığı bilinmektedir. Bu bağlamda ilk yaklaşımımız opsiyonların fiyat dağılımını (hisse / işlem fiyatı) analiz etmek olmuştur. Veri Kümesi, parasallık sınır çizgisinden uzaklığa göre 0,1'den 0,4'e kadar farklı eşiklerle iki bölgeye ayrılmıştır. Eşik, opsiyonların parasallık çizgisine ne kadar uzakta olduğunu gösterir. Örneğin, 0.1 eşik için, hisse/işlem fiyatı oranı 0.9-1.1 arasında yer alan opsiyonlar parasallık çizgisi civarı kalanlar ise uzağı olarak belirlenmiştir. Şekil 12, farklı eşikler için BS opsiyon fiyatlarının yukarıda belirtildiği gibi farklı eşik değerlerine göre sınır çizgisi civarı veya uzağı olarak iki bölgeye ayırıp bu bölgelerdeki hata ortalamasını ve oransal olarak bu bölgelerde bulunan opsiyonları göstermektedir. Görüldüğü üzere eşik arttığında, BS hesaplamasının uzak bölgesi kötüleşir. Bu şekillere bakıldığında 0.2 eşik uzak bölgede yeteri kadar veri bırakması ve uzak bölgede kalan verilerin de aynı zamanda baş edilebilecek kadar yüksek hataya sahip olması sebebiyle seçilmiştir. Sonuç olarak, veriler 0.2 eşik değerine göre %79 civar ve % 21 uzak alarak ikiye bölünmüş ve Şekil 13 yapılandırılmıştır. Tasarım rakamında görüldüğü gibi, ilk aşamadaki veriler hisse/işlem fiyatına göre sınıflandırılır, daha sonra parasallık çizgisinin civarindaki opsiyonlar BS kullanılarak hesaplanırken kalan opsiyonlar YSA'ye verilir.

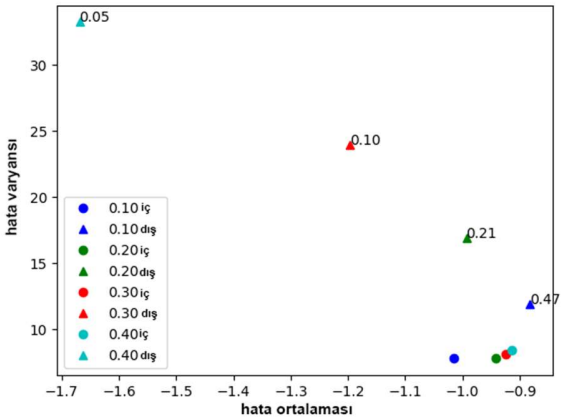

Şekil 12. Eşik değere göre parasallık sınırı civarı ve uzağında kalan bölgelerdeki hara ortalama ve varyans değerleri (Daireler, parasallık sınırına belirtilen eşik değeri kadar uzaktaki opsiyonşarı üçgenler ise bu alanın dışında kalan opsiyonları belirtmektedir.Üçgenlerin ilgili eşik değeri ile oluşturduğu bölgedeki opsiyonların tüm opsiyonlara oranı yanlarında verilmiştir.)

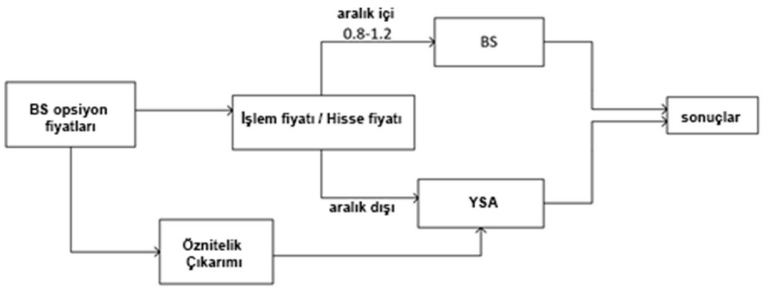

Şekil 13. VS-BS/MLP dizaynı

Yine, 25 farklı doğrulama setiyle, ortalamanın ortalama, varyans çifti (0.84686, 0.00003) olarak ve varyansın ortalama, varyans çifti (7.93791, 0.00012) olarak elde edilmiştir (Şekil 11). Sonuçlar, sonucun tek başına BS formülünü kullanmaktan daha iyi olduğunu, ancak tek aşamalı YSA tahmininden daha kötü olduğunu göstermektedir. Bunun nedeni, uzak bölgede, opsiyonların işlem hacimlerinin daha az olması nedeniyle fiyat değerlerinin makul değerleri yansıtmadan aşırı derecede değişme gösterdiğinden olabilir. Bu durumda, YSA öğrenme süreci bir model oluşturmakta güçlük çekmektedir.

1.A.3.2.2. VS-MLP/MLP

Bu yaklaşımla VS-BS / MLP modeline benzer bir yapı oluşturulmuştur. Tek fark, bölgelerin iki tarafının da **Error! Reference source not found.**'deki gibi farklı YSA modellerine beslenmesidir.

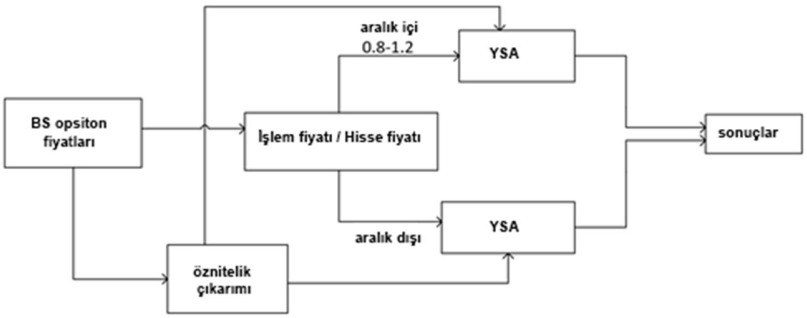

Şekil 14. VS-MLP/MLP dizaynı

BS formülünün kullanılacağı bölgedeki ilave YSA'nin kullanılması ortalama hatanın (ortalama, varyans) çiftini (0.22117, 0.00080) ve varyansın (ortalama, varyans) çiftini (6.22691, 0.00345) yapmıştır (Şekil 11). Bu sonuçlarla, YSA'nin parasallık sınırı civarı bölgeyi genel performansta uzak bölgedeki hataları dahi telafi edecek kadar iyi öğrendiği söylenebilir.

1.A.3.2.3. C-BS/MLP

Bu modelde, Şekil 15da gösterilen veri akışı oluşturulmuştur. Opsiyon fiyatını volatilite gülümsemesine dayanan yaklaşımda olduğu gibi (işlem/hisse fiyat oranı) inceleyerek opsiyon fiyatını hesaplamak için BS veya MLP'nin kullanılıp kullanılmayacağına karar vermek yerine, karar verici olarak YSA bazlı bir sınıflandırıcı kullanılır.

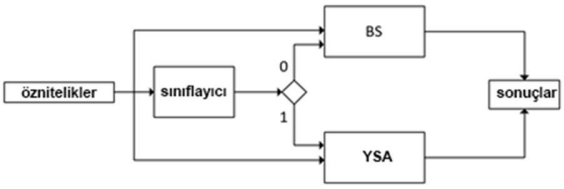

Şekil 15. C-BS/MLP design

Bu yapıyı inşa etmek için veriler yine sınıflandırma modelinde eğitim (\% 80) ve test (\% 20) olarak 2 farklı bölüme ayrılmıştır. Bu yaklaşımda, sınıflandırıcı, BS hatası 1'e eşit olan opsiyonlarla beslenir. 1 Hata BS formülünün mü yoksa YSA'nin mi kullanılacağına karar vermek için ayırma eşik seviyesidir. Sınıflandırıcı veri setini oluşturmak için, eğitim veri setinde, BS hatası <1 0 olarak kalanlar ise 1 olarar etiketlenmiştir. Karar çizgisi olarak BS hatası = 1 seçimi, verilen BS hata sınır değeri için sınıflandırma ayrımı ve sınıflandırma performansı analiz edilerek seçilmiştir. BS hatasının farklı sınır değerleri için performans ve ayırma oranları analizi ve Şekil 16'da görülmektedir. Bu grafiği analiz ederek, eşik 1'in, veriyi neredeyse eşit (\% 45) bölgelere ayırdığı ve nispeten iyi performans sergilediği görülmüştür. Sınıflandırıcı için veri normalize edilmiş ve 12 öznitelikleri kullanılmıştır. Karar vermede hata 0.0614 olmuştur.

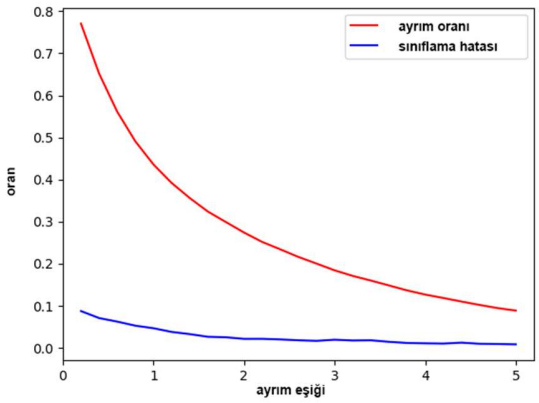

Şekil 16. Eşik değerine bağlı ayrım oranı ve hata

Model, önceki tasarımlardan (Şekil 11), ortalama hata (ortalama, varyans) çifti (0.08909, 0.00014) ve varyans (ortalama, varyans) çifti (3.44267, 0.00024) ile daha iyi performans göstermektedir. Görüldüğü gibi, hata istatistiklerinin yerelleştirilmesi de önemli ölçüde iyileştirilmiştir. Özellikle MLP ve VS-MLP/MLP ile karşılaştırıldığında, hata ortalamasının varyansı daha iyi lokalize olmuş ve bu da sistemi daha güvenilir kılmıştır.

1.A.3.2.4. C-MLP/MLP

Bu son model olarak, BS tabanlı sınıflandırıcı tek bir güncelleme ile yeniden tasarlanmıştır. Verilerin bir kısmının hesaplamalarını, BS tabanlı yaklaşıma göre sınıflandırıcı çıkışı BS'ye bırakmak yerine, BS olarak etiketlenen kısım da, başka bir YSA'ye verilmiştir (Şekil 17). Tüm tasarımlar arasında en iyi performans elde edilmiştir (Figure \ref{figmodelcompare}). Modelin 25 faklı set için oralama hata (ortalama, varyans) çifti(0.01197, 0.00012) ve varyans (ortalama, varyans) (3.42771, 0.00041)'dir. Görüldüğü gibi iyileşme temelde hata ortalamasında olmuştur. Bu şekilde BS'yi YSA'ye değiştirmek basitçe tüm değerlerden sürekli bir sabiti çıkartmak gibidir. Bu da BS'nin "civar" bölgesinde küçük bir sabit uzaklaşma ile gayet iyi çalıştığını kanıtlamaktadır.

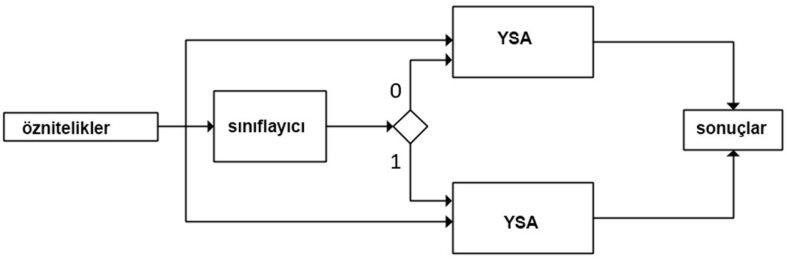

Şekil 17. C-MLP/MLP dizayn

1.A.3.2.5. C-MLP/MLP-opt

Bu gelişmeler ile, önerilen tüm modeller arasında en iyi model (C-MLP / MLP), BS hatasının sınıflandırma eşiği noktasından optimize edilmiştir. Önceki bölümlerde bahsedilen analizle BS hatası = 1 sınıflandırma noktası olarak seçilmiştir, ancak genel sonucu daha da iyi yapan daha iyi bir nokta olabilir. En uygun noktayı bulmak için simpleks algoritması kullanılmıştır. Bir noktanın maliyeti, 3 farklı doğrulama kümesi sonucunun ortalaması ile

hesaplanmaktadır. Maliyet ortalama hata + ortalama varyans olarak belirlenmiştir. Durma kriterleri (üçgen uzunluğunun en uzun kenarı <0,1) olarak seçilir. 6 farklı uygulama ile 3.72294, en iyi BS hata eşiği olarak bulunmuştur. Bu eşikle oluşturulan C-MLP / MLP modeli farklı doğrulama setleriyle 25 kez çalıştırılmış ve her çalışma Şekil 11'de işaretlenmiştir. Görüldüğü gibi, optimum tasarım ile sonuçlar iyileşmiş hata ortalaması (ortalama, varyans) çifti (0.01254, 0.00005) ve varyans (ortalama, varyans) çifti (1.81221, 0.00003) olmuştur.

Dahası, C-MLP / MLP tasarımı, Şekil 18 'da olduğu gibi sınıflandırılmış grupların sayısını optimize etmek için dinamik forma dönüştürülmüştür. Bu tasarımda, "one vs rest" yaklaşımı kullanılmış ve çok etiketli sınıflar artan bir sırada oluşturulur. Örneğin, C-3MLP için, BS hatasında en optimal 2 nokta bulunmuş, veriler 3 farklı gruba bölünmüştür. Bu grupların, opsiyon fiyat tahminleri için ikinci aşamada ayrı ayrı 3 YSA regresörü kullanılmıştır. Artan sınıflandırılmış grupların her bir yapısı için, BS hatasının optimal sınıflandırma noktalarını bulmak için simpleks algoritması kullanılır. Her sınıflandırma modülünde en iyi nokta ve maliyetler Şekil 19 ve Tablo 14'de görülmektedir. Görüldüğü gibi, dinamik yapı, C-4MLP tercihine karşılık gelen 3 eşikli kullanımda yakınsar. C-4MLP-opt tasarımı, sınıflandırma için Tablo 14'da olduğu gibi belirtilen en optimal BS hata noktalarıyla birlikte oluşturulan yapı 25 farklı doğrulama kümesi için yürütülmüştür. Tasarım Şekil 11de olduğu gibi diğer tüm tasarımlardan çok daha iyi sonuç sergilemiş ve ortalama hatada (ortalama, varyans) çifti (0.00583, 0.00001) ve varyansta (ortalama, varyans) çifti (0.59808, 0.000006) ile aynı zamanda en güvenilir dağılımı oluşturmuştur.

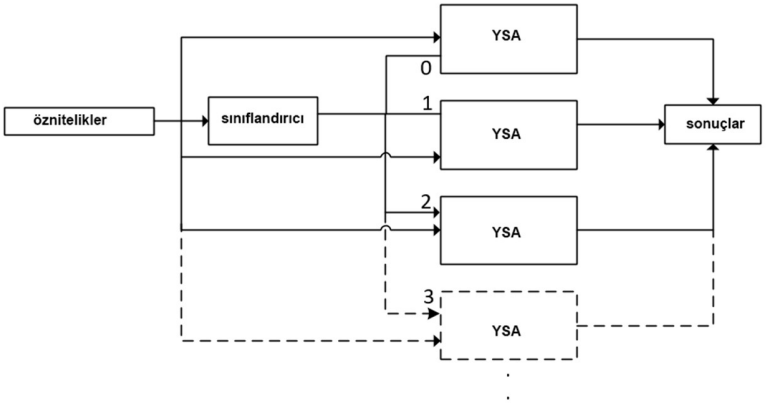

Şekil 18. C-MLP dinamik dizayn

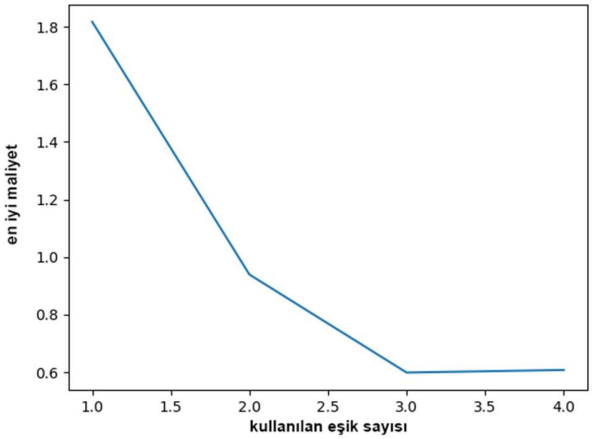

Şekil 19. C-MLP dinamik dizaynında sınıflandırmada kullanılan eşik sayısına göre optimal maliyet

Dizayn	**Sınıflandırıcıda kullanılan noktalar (BS hata değerleri)**	**Maiyetler (hata ortalaması+varyansı)**
C-MLP/MLP-opt	3.72294	1.81685
C-3MLP-opt	6.41775, 2.03732	0.93959

C-4MLP-opt	10.46663, 4.84905, 1.75439	0.59919
C-5MLP-opt	7.18496, 4.43073, 3.84005, 1.73978	0.60822

Tablo 14 C-MLP dinamik dizaynında artan ayrım noktasına göre seçilen en iyi noktalar ve maliyetleri

Edinilen sonuçlarla model kıyaslaması yapılmıştır. Şekil 11 ve Tablo 13'de görüldüğü gibi, BS tüm modeller arasında en kötüsüdür. BS hatasına dayalı sınıflandırıcı kullanımı, genel olarak iyi sonuç vermiştir. Doğrudan BS hatasını kullanmak uçuculuk gülüşü temelli yaklaşımlardan daha iyi bi seçenektir. Bir başka performans atlaması, kullanılacak sınıf sayısı ve ayrım noktalarının optimizasyonunda gerçekleşmiştir. BS dışındaki tüm modeller pozitif hata ortalamasına sahiptir. Şekil 11ve istatistiklerin gösterdiği gibi, -opt uzantılı modeller hariç her zaman hata ortalamasının varyansı hata varyansının varyansından daha yüksektedir. Bu da temel olarak dağılımların benzer oluğuna ama grupların hata miktarlarında küçük kaymalar yaşadığına işaret eder. Benzer şekilde, optimizasyon da dağıtımların aynı şekilde olmasını sağlar, dolayısıyla modeller daha güvenilir hale gelir.

Ayrıca, tüm bu 25 farklı uygulama için, fiyatlamanın ortalama karesel hataları (MSE) hesaplanmıştır (Tablo 13). MSE istatistiğindeki sonuçlar, modellerin hata ortalamalarını ve varyans davranışlarını takip eder. Görüldüğü gibi, sınıflandırıcı temelli 4 sınıf yaklaşımı diğer tüm modellerden önemli ölçüde daha iyi performans göstermektedir. Ayrıca, Tablo 13 varyans değerlerine bakıldığında ise dağılımların çok dar bir varyansa sahip olduğu görülmektedir. Bu da modellerin güvenilirliğine işaret eder.

Bu çalışmada kullanılan modeller, çoğu durumda opsiyon fiyatlarının hesaplanmasında BS formülünden daha iyi performans sergilemektedir. Sonuçların değişkenliği hala iyileştirme için bir alan olduğunu göstermektedir. Gelecekteki çalışmalar için aşağıdakiler eklenebilir:

- İşlem fiyatının hisse senedi fiyatından çok uzakta olduğu veya opsiyonun işleme sokulacağına dair neredeyse hiç bir beklentinin olmadığı opsiyonlar için, opsiyon fiyatları 1 sent sabit etiketlemeyle elemine edilebilir.
- Önerilen tüm yöntemler farklı opsiyon dinamikleri üzerine analiz edilebilir ve verilen opsiyon için en iyi modeli seçen bir karar ağacı modellerin tepesinde eklenebilir.
- XGBoost ağaçları veya DNN (Derin Sinir Ağı) gibi diğer bazı yöntemler YSA yerine kullanılabilir.
- Hisse fiyatının zaman serisi, doğrudan ANN yaklaşımlarına aktarılabilir veya LSTM (Uzun Kısa Süreli Bellek) gibi zamana dayalı öğrenme algoritmaları, oynaklık özelliği olarak günlük getiri bazlı varyans kullanmak yerine daha iyi oynaklık elde etmek için kullanılabilir.
- Gün sonu hisse senedi fiyatı ve hacmi de tahmin edilebilir ve bu şekilde opsiyon fiyatlandırması hesaplaması günün sonundan günün başlangıcına kaydırılabilir.
- [23]'deki hacim ve volatilite arasındaki korelasyon gibi ya da yatırımcıların [24] zarardan kaçınma özelliği gibi piyasa dinamikleri analiz edilip entegre edilebilir.
- Belirtildiği gibi hatanın kuyrukları analiz edilebilir ve bu opsiyonlar için algılama-dönüşüm çifti uygulanabilir.
- [25]'de belirtildiği gibi, varlığa bağlı olarak, farklı volatilite hesaplamaları daha iyi sonuçlar verir. Bu nedenle, diğer oynaklık hesaplama yöntemleri, oynaklık hesaplama aşamasında eklenebilir ve birleştirilebilir.
- Parasallık ayrım çizgisinin iki tarafı farklı değerlendirilebilir.
- Performans ölçümü hata olarak kabul edilmiştir ve tüm modeller, buna göre eğitilmiştir, eğer görecelik kazanç ise bu seçim iyi olmayabilir. Bu gibi durumlarda hata / hisse fiyatı oranı kullanılabilir. Fakat bu durumda da, düşük fiyatlı opsiyonlar için kayıp, değer açısından önemli olmasa da, oran olarak çok fazla görülebilir. Bu nedenle, farklı opsiyon türleri için farklı performans metrikleri kullanılabilir.
- Opsiyonlarda hacmine bağlı olarak farklı yaklaşımlar kullanılabilir keza düşük hacimli opsiyonların fiyatları pazarın gerçek fiyatını yansıtmayabilir.
- Alış-satış fiyatı yayılımı bir öznitelik olarak eklenebilir.
- Dinamik yapıdaki BS hatasına göre bölünmüş bölgeler analiz edilip yeni öznitelikler eklenebilir.

Bu çalışmada, opsiyon fiyatlama için bazı hibrit sinir ağı modelleri önerilmiştir. Öncelikli amacımız, opsiyon fiyatının hesaplanmasında yaygın olarak kullanılan bir teknik olan BS formülünü geride bırakmaktı. Sonuçlarımız, bazı sinir ağı bileşimleriyle daha iyi tahmin sonuçları elde etmenin mümkün olduğunu göstermektedir. YSA tabanlı sınıflandırıcı modelimizin performansı, böyle bir modeli gerçek opsiyon alım satım ortamlarında kullanmanın mümkün olduğunu göstermektedir. Opsiyon fiyatlama açısından, yıllığa çevrilmiş 20 gün içi kazancı oynaklık olarak kullanan BS ile karşılaştırıldığında, toplam kare hatasında ortalama % 94,5'lik bir iyileşme elde edilmiştir.
Bu iş paketinde trend ve değer tahmini için zaman serisi tabanlı verilere bağlı derin öğrenme modeli geliştirilmesi ile ilgili çalışmalar ve derin öğrenme ile teknik analiz tabanlı alım-satım modeli geliştirilmesi aktiviteleri bulunmaktadır. Bu konular ile ilgili çalışmalar önceki dönemde başlamış olduğundan önceki gelişme raporlarında konu ile ilgili literatür taraması verilmiştir.

1.A.4. IP? Çalışmaları

1.A.4.1. Apache Spark Benchmark

MLLIB üzerindeki Linear Reggression fonksiyonu ile finans verisi üzerinde değişik çekirdek sayısı ve data büyüklükleri kullanılarak test edilmiş ve sonuçlar saniye cinsinden alınmıştır. Küçük verilerde çekirdek sayısının katkısı olmadığı, büyük verilerde ise tek çekirdek ile 8 çekirdek arasında yaklaşık 6 katlık (3698 saniye) fark olduğu gözlenerek, büyük verilerde Spark kullanmanın avantaj sağladığı gözlenmiştir.

Bu çalışmada AAPL (Apple Inc. NASDAQ) verisi üzerinde Apache Spark MLLIB kütüphanesi kullanılarak Linear Regression uygulanmıştır. Sistem değişik büyüklüklerde veriler ve değişik çekirdek sayıları ile denenmiş ve hız ölçümleri alınmıştır. Amacımız veri büyüdükçe Spark'ın sağladığı faydaları gözlemlemektir.

1.A.4.1.1. Veriseti

Open, High, Low, Close, Volume ve Adj Close vektörlerinden oluşan AAPL (Apple Inc. NASDAQ) verisi kullanılmıştır. Spark'ın büyük veri büyüklüğüne tepkisini gözlemleyebilmek amacıyla veri istenen boyuta gelene kadar arka arkaya eklenmiştir. Veri ile ilgili istatisliklerTablo 15. Dataset İstatislikleri Tablo 15'den görülebilir. Adj Close vektörü label olarak ayrılmış diğer vektörler ise öznitelik olarak kullanılmıştır.

Tablo 15. Dataset İstatislikleri

summary	count	mean	stddev	min	max
Date	9534	9.413206708621775E8	3.445064029577415E8	3.454164E8	1.5384276E9
Open	9533	25.227877389069594	45.035747904623484	0.198661	228.990005
High	9533	25.46629224934435	45.402302820535645	0.198661	230.0
Low	9533	24.976618823979813	44.669427190260855	0.196429	226.630005
Close	9533	25.227376554914493	45.04640919574818	0.196429	229.279999
Adj Close	9533	23.66256029403127	43.507792038119455	0.158904	229.279999
Volume	9533	8.787442552187139E7	8.695796711275896E7	347200.0	1.8554102E9

1.A.4.1.2. Benchmark

1.A.4.1.2.1. Sabit Veri Büyüklüğü İçin Değişen Çekirdek Miktarı

Denemenin ilk kısmında veri boyutu sabit tutularak çekirdek sayısı değiştirilmiştir. Veriler 1B, 10B ,100B, 1KB, 10MB olarak sisteme verilmiş ve çekirdek sayısı 1'den 8'e kadar arttırılmıştır. Şekil 20 ve Şekil 21' deki sonuclar incelendiğinde küçük verilerde çekirdek sayısının artışının hıza mantıklı şekilde etkisi yokken (1 MB için 1 çekirdek 2.49 sn, 8 çekirdek 2.46 sn) büyük verilerde (10k mb için 1 çekirdek 4426 sn, 8 çekirdek 728.79 sn) ciddi kazanımlar elde edilmiştir.

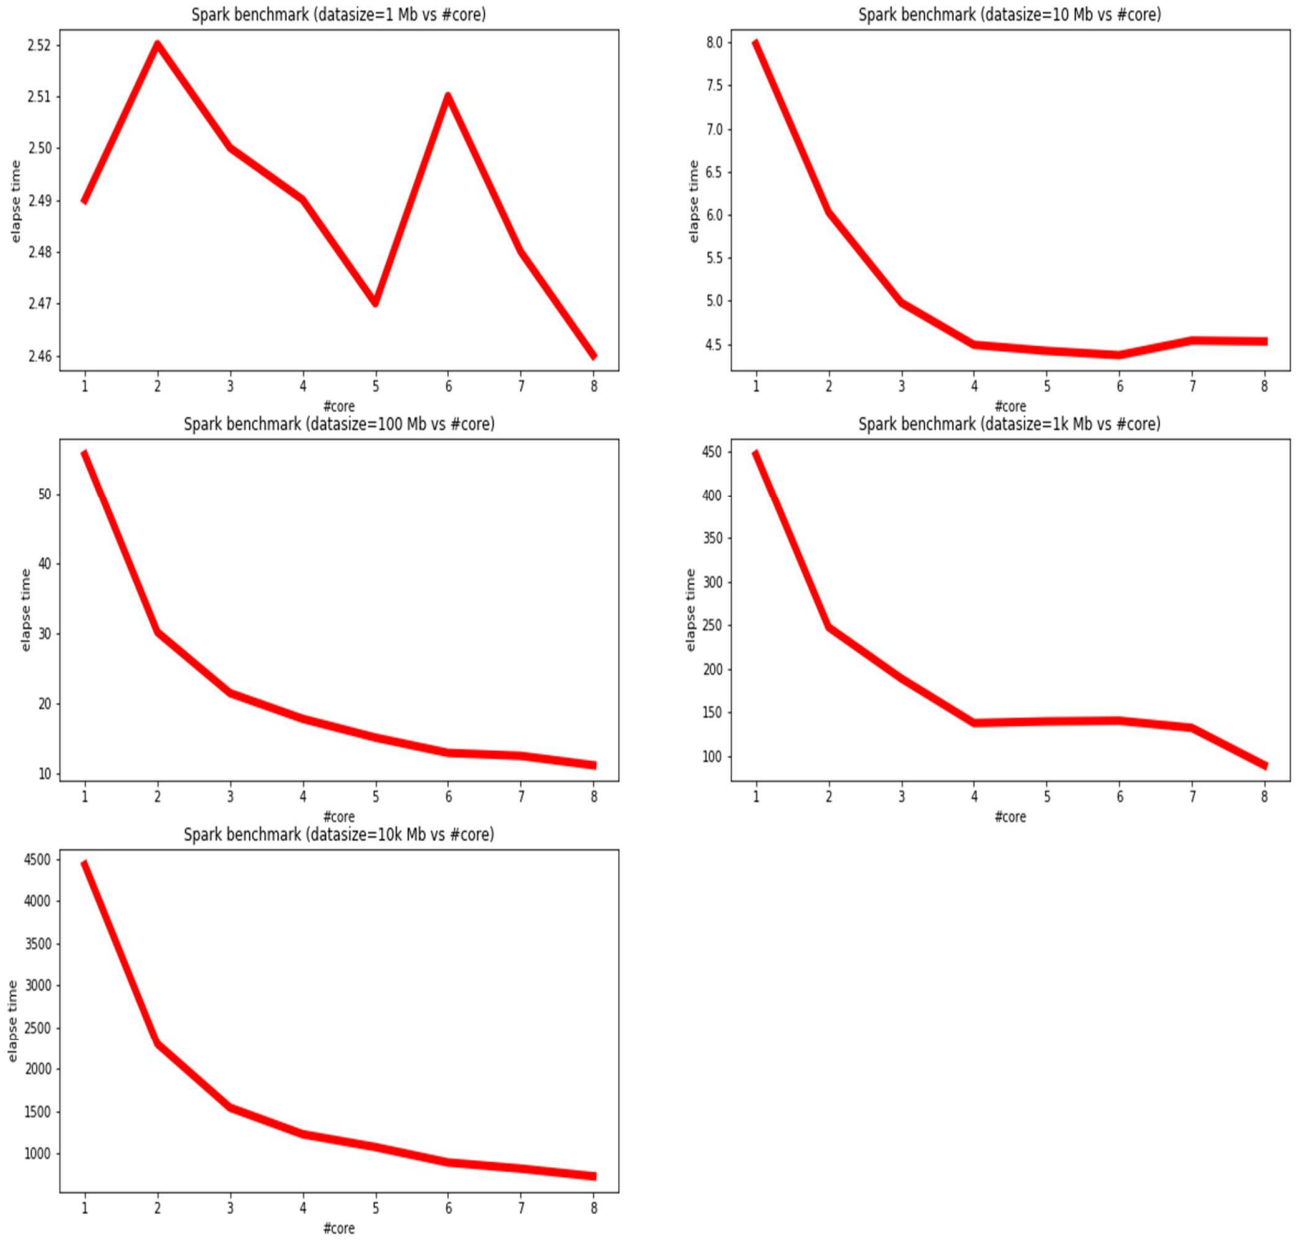

Şekil 20. Sabit veri boyutu için değişen çekirdek sayıları hız grafikleri

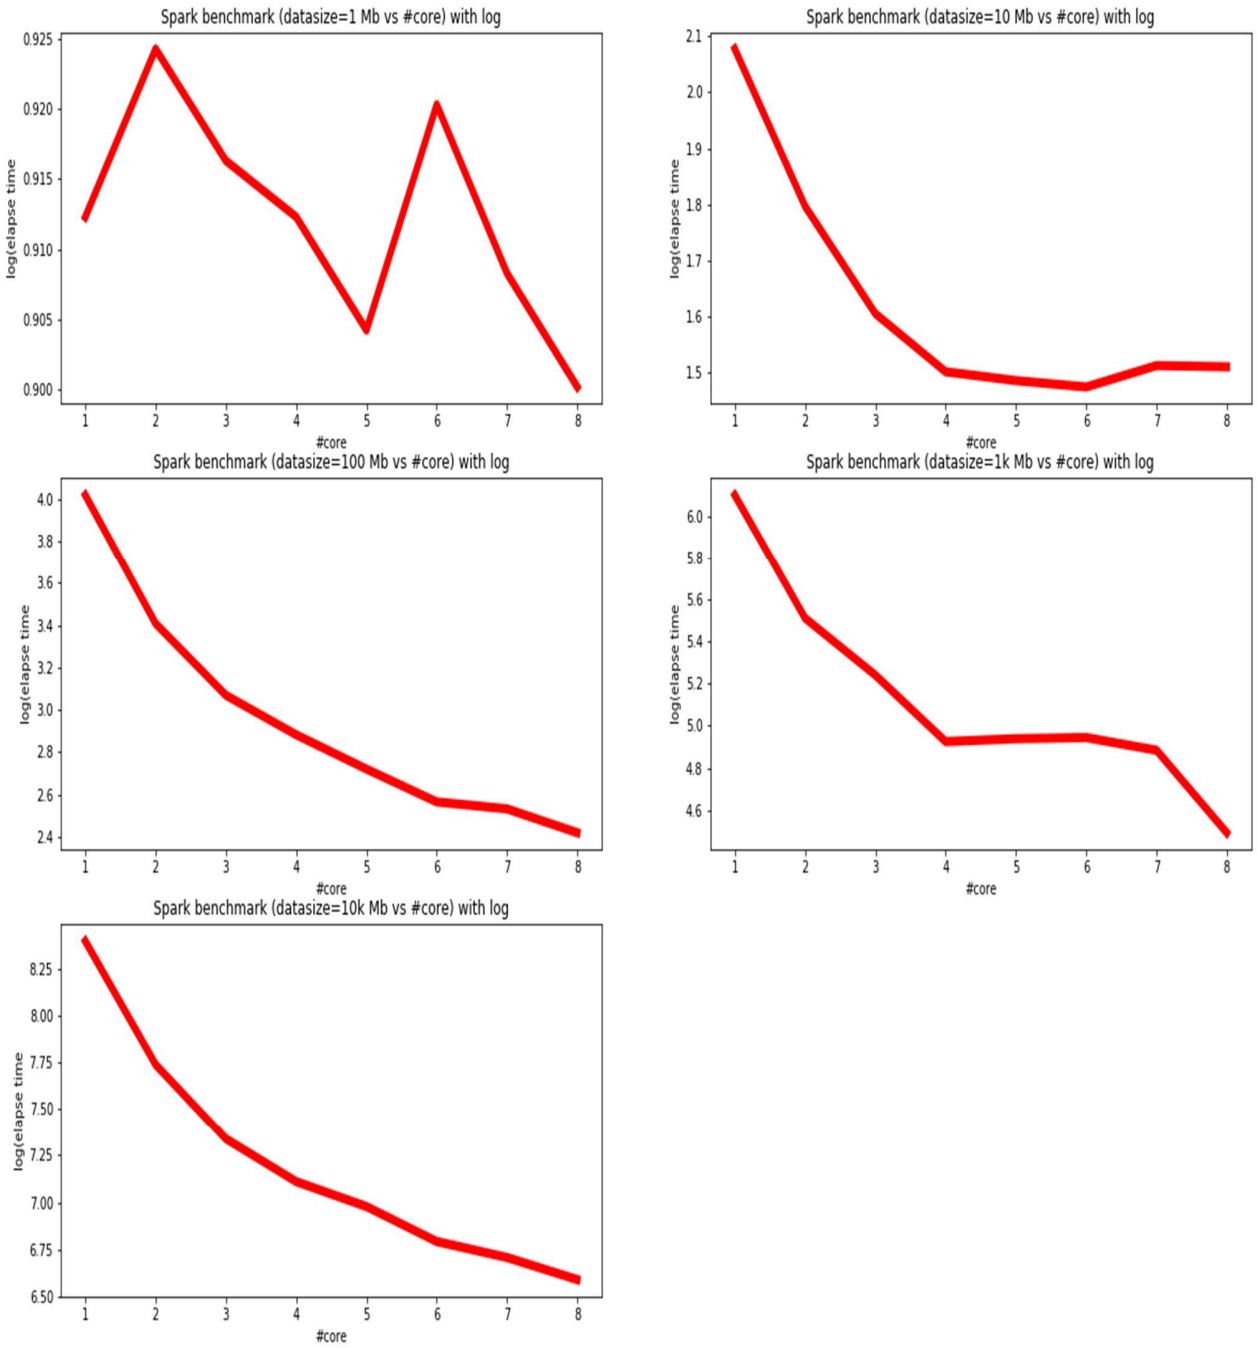

Şekil 21. Sabit veri boyutu için değişen çekirdek sayıları hız grafikleri (logaritmik)

1.A.4.1.2.2. Sabit Çekirdek Sayısı İçin Değişen Değişken Veri Büyüklüğü

Bu kısımda sabit çekirdek sayısı için veri boyutu değiştirilmiştir. Çekirdek sayısı 1 den 8 e kadar verilmiş, veriler 1B, 10B ,100B, 1KB, 10Mb olarak arttırılmıştır. Şekil 22 ve Şekil 23' deki sonuclar incelendiğinde düşük çekirdek

sayısı az olduüunda elapse time veriye büyüklüğüne bağlı olarak çok fazla artış gösteriyor ancak çekirdek sayısı arttırıldığında veri büyümesine bağlı geçen zaman artışı lineere yaklaşıyor.

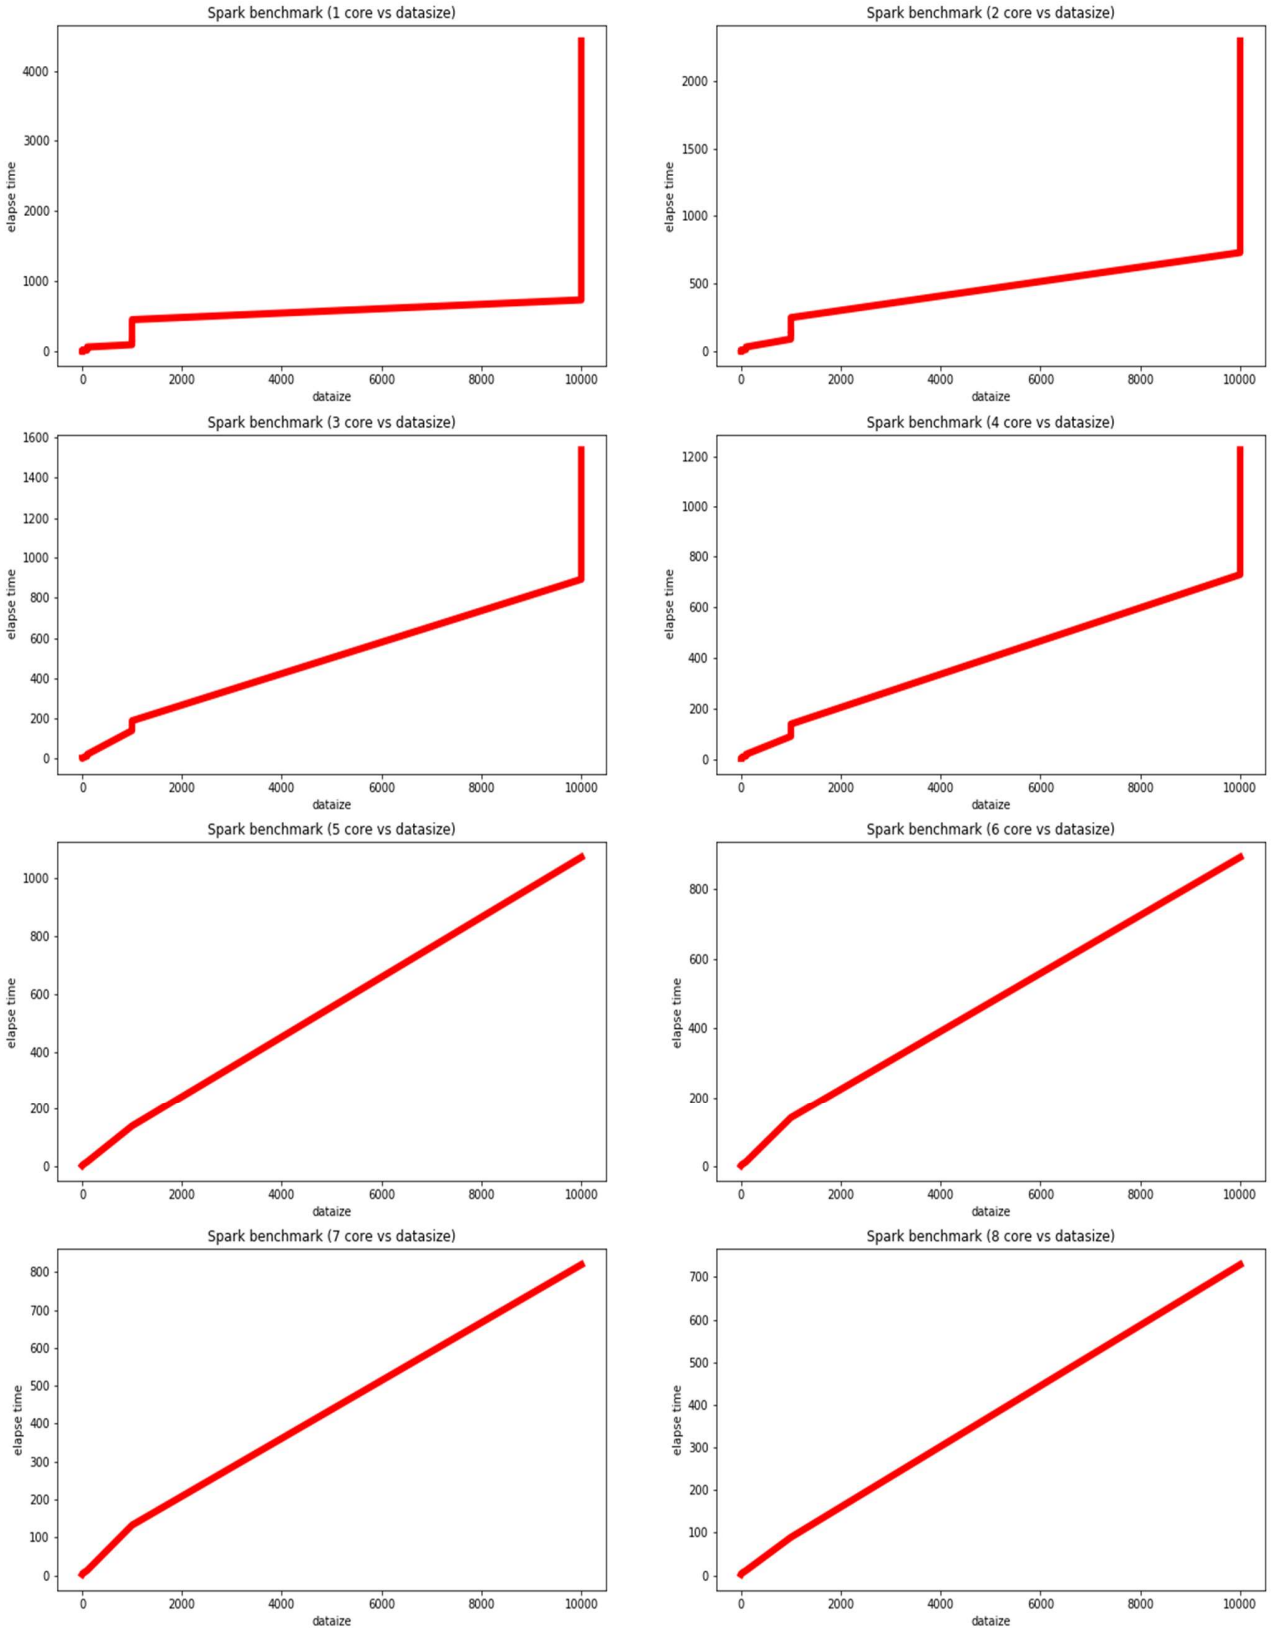

Şekil 22. Sabit çekirdek sayısı için değişen veri büyüklüğü grafikleri

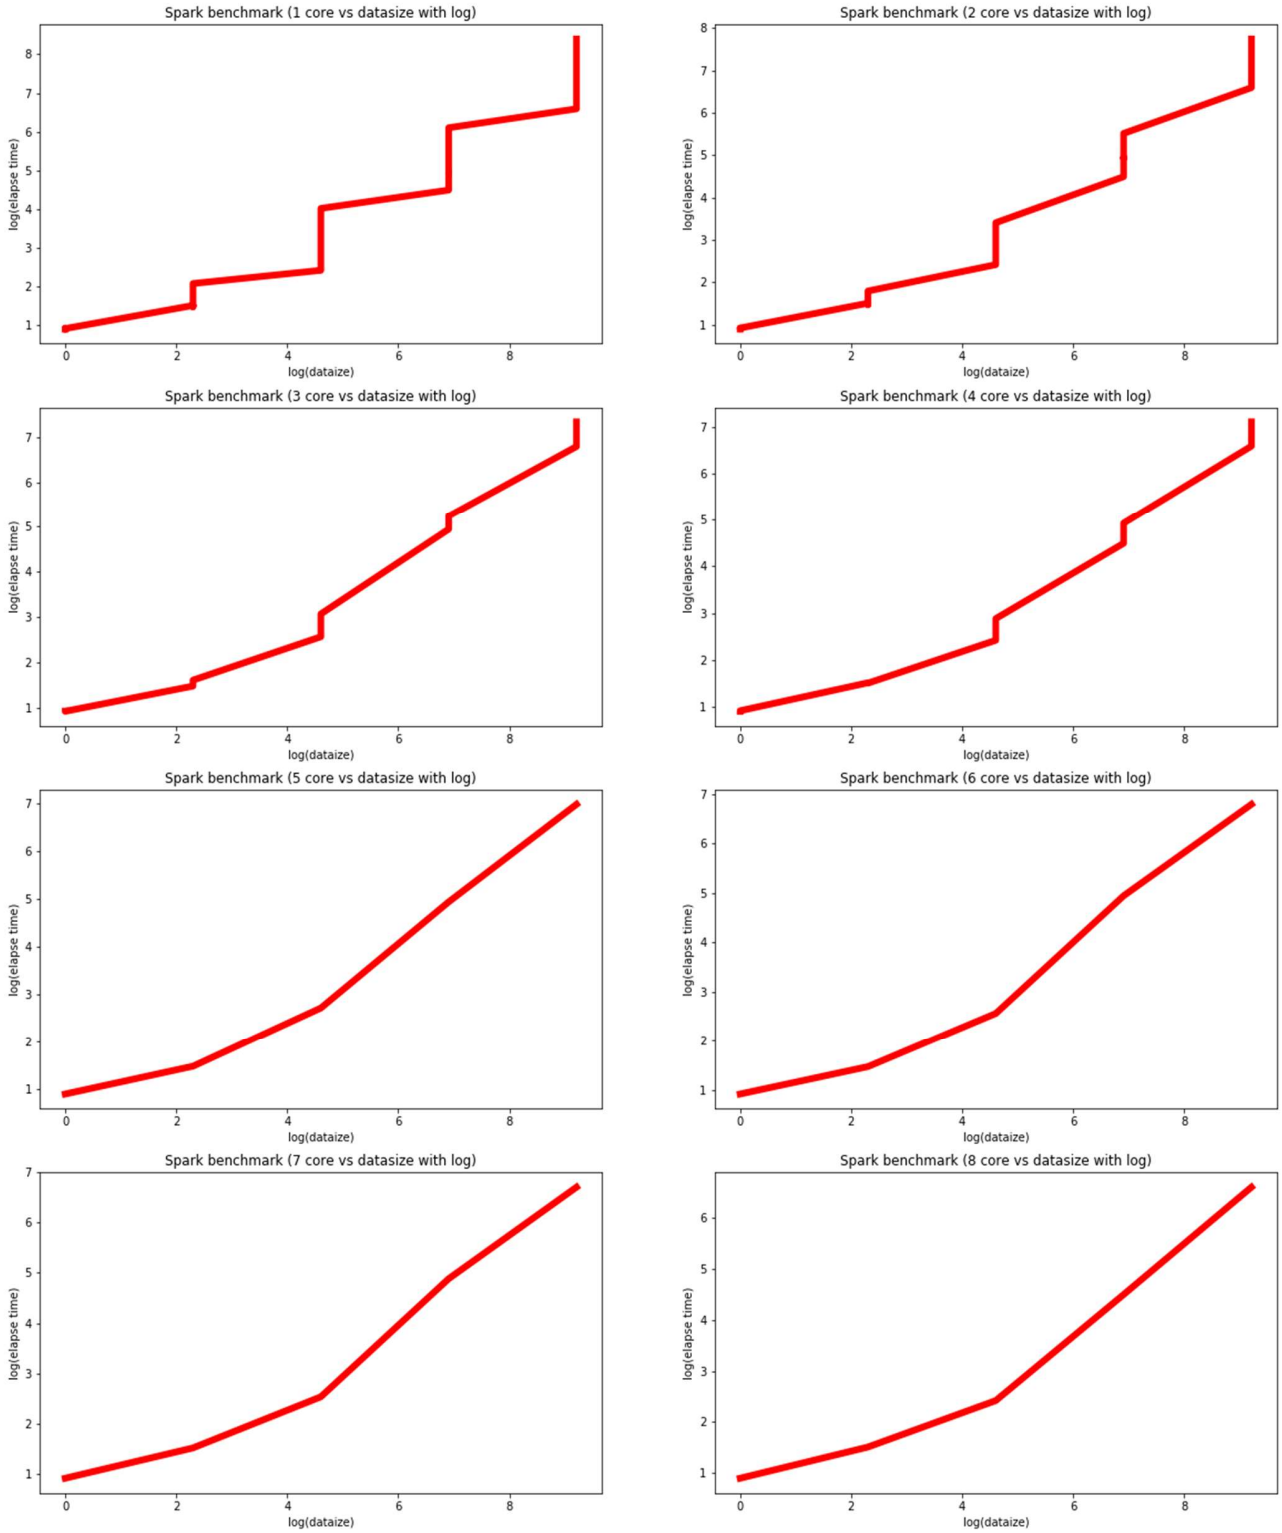

Şekil 23. Sabit çekirdek sayısı için değişen Veri Büyüklüğü grafikleri (logaritmik)

1.A.4.1.2.3. Hızlandırma

Şekil 24'deki hızlandırma grafikleri incelendiğinde Şekil 22 ve Şekil 23'ü doğrulayan sonuçlar görülecektir. Küçük verilerde neredeyse hiç kazanç sağlanamamış, veri büyüdükçe ideale yakınsamaya başlamıştır.

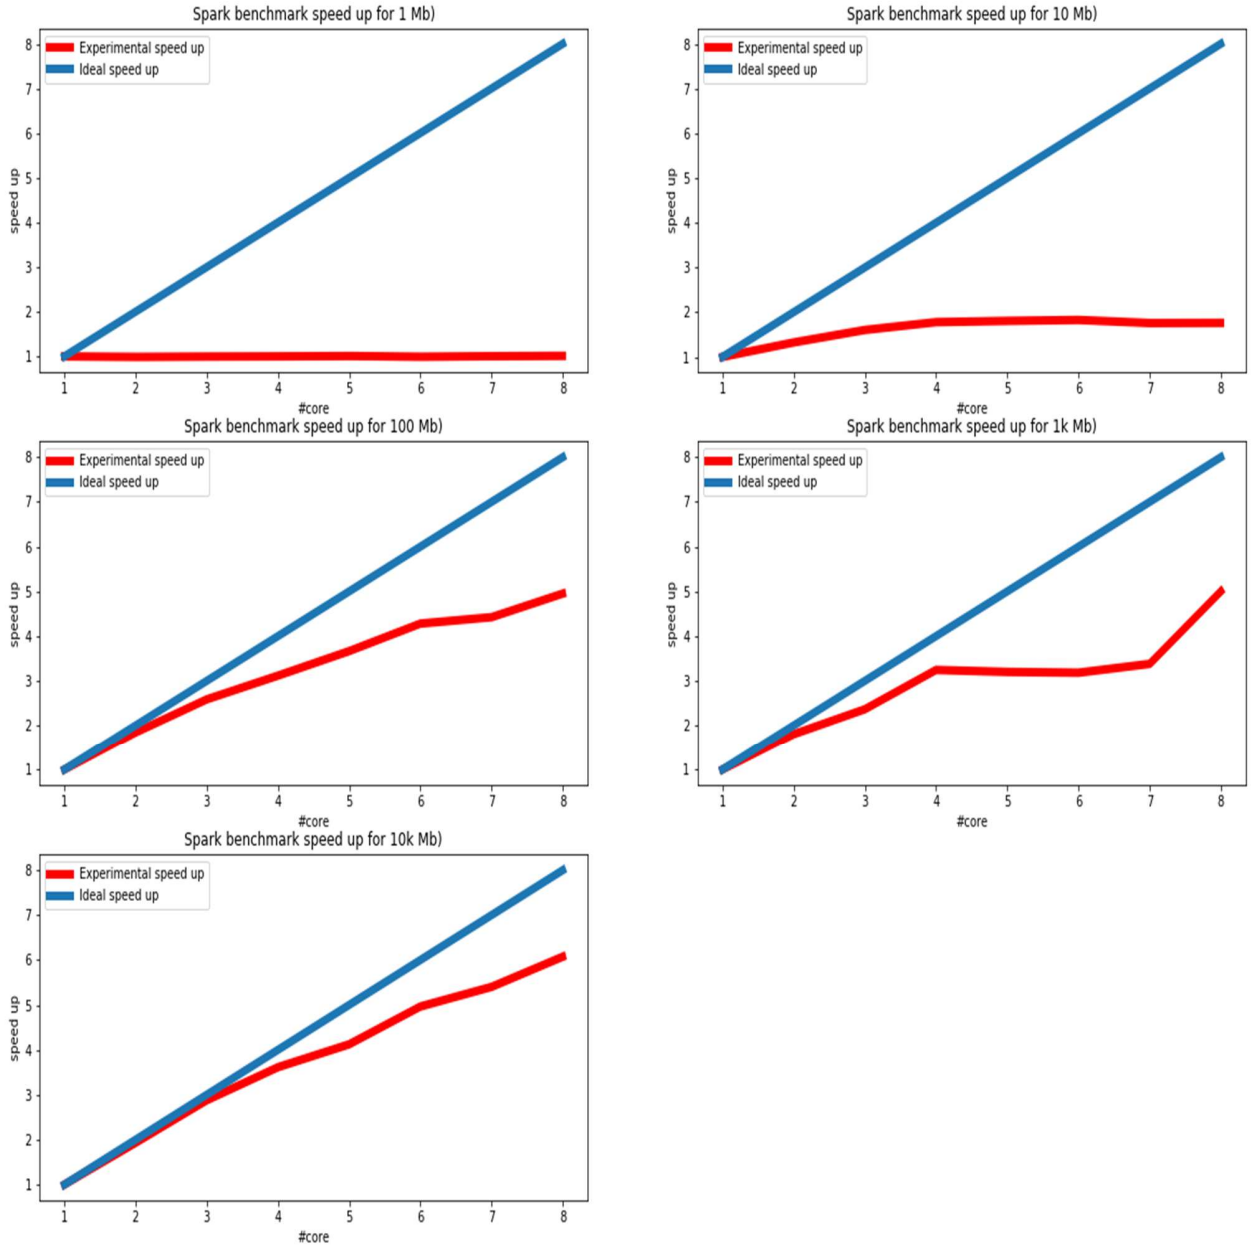

Şekil 24. Farklı Veri Büyüklükleri İçin Hızlandırma

1.A.4.1.2.4. Sonuçlar

Tablo 16. Benchmark(#çekirdek vs veri buyuklugu) sonuclari(saniye)

	1	2	3	4	5	6	7	8
1 Mb	2.49	2.52	2.5	2.49	2.47	2.51	2.48	2.46
10 Mb	7.98	6.03	4.98	4.49	4.42	4.37	4.54	4.53
100 Mb	55.6	30.17	21.5	17.84	15.17	12.99	12.57	11.23
1k Mb	446.68	247.61	188.86	137.69	139.61	140.37	132.16	89.28
10k Mb	4426.33	2293.38	1538.47	1225.01	1073.47	891.45	819.45	728.79

Benchmark sonuçları Tablo 16'de verilmiştir. Bu verilerle Şekil 25 ve Şekil 26 de görselleştirilmiştir. Şekil 26'de görülebileceği gibi küçük verilerde kazanç sağlanamazken veri büyüdükçe ciddi kazançlar elde edilmiştir.

Küçük verilerde Spark'ın verimsiz olmasının sebebi Spark'ın sahip olduğu overhead diğer araçlara göre daha fazladır. Veri küçük olduğunda overhead normal çalışma süresinin önüne geçeceğinden negatif performans olarak etki gözlenir. Veri büyüdüğünde overhead oransansal olarak çalışma süresine göre küçük kalacağından yoksayılabilir, bu durumda Spark'ın avantajları görülebilir.

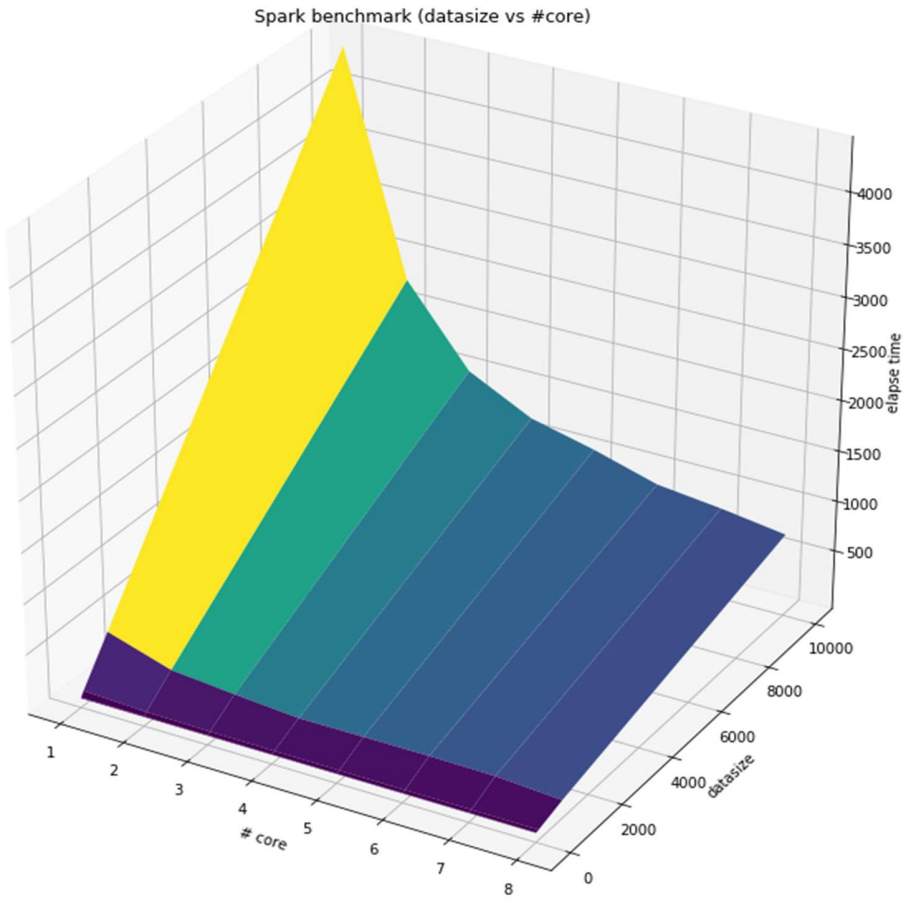

Şekil 25. Benchmark Sonuçları

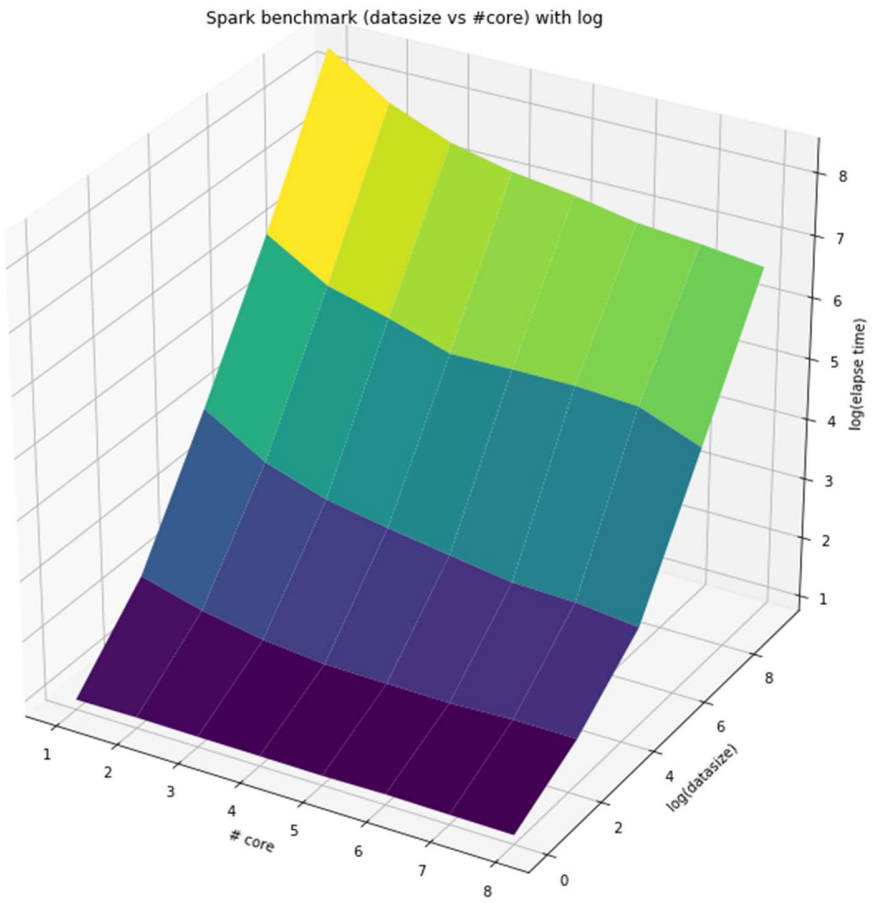

Şekil 26. Benchmark Sonuçları (Logaritmik)

1.B. Dönem İçinde Projeyle İlgili Teknik Gelişmeler:

1.B.1. Hızlı Prototip Sistemi Geliştirilmesi

Gerek strateji geliştirirken, gerekse backtest esnasında verilerle ve modellerle daha kolay sistem kurabilmek için varolan yapıyı uygun ve kolay bir şekilde kurgulama ihtiyacı ortaya çıkmıştır. Genelikle, problemlere özgü çalışmalar yaparken küçük şeyler değiştiriyor olsak bile, tüm yapıyı baştan inşa etmeye çalışıyoruz. Biz bunun önüne geçebilmek ve yeni prototip modelleri test edebilmek için 'Deney' adı altında problemi çözmek ve raporlamak için gereken yapıları barındıran bir 'framework' oluşturduk. Şekil 1'de bu yapının genel hali görülebilmektedir.

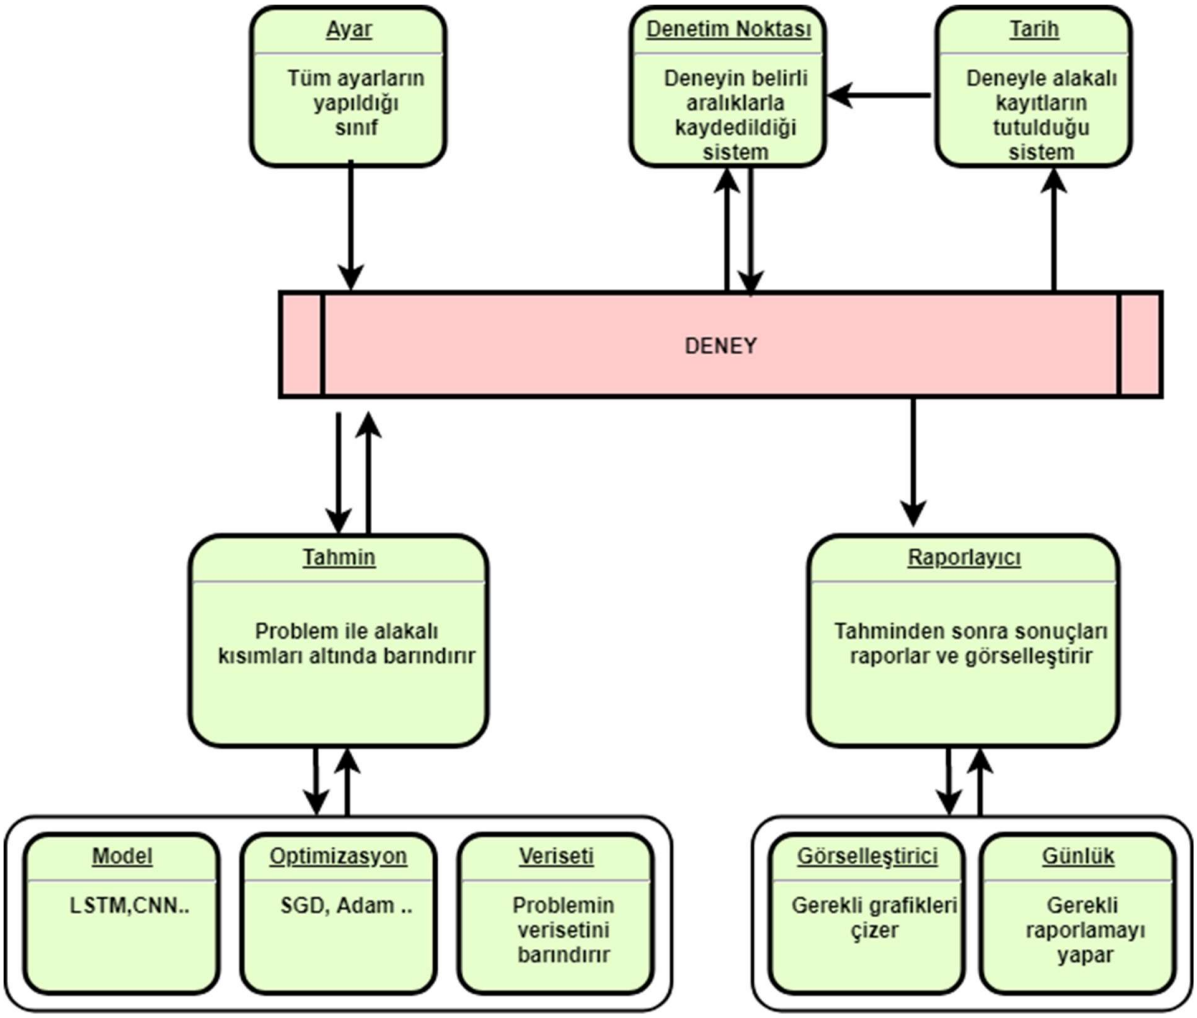

Bu yapıları sırasıyla inceleyecek olursak;
Deney: Tüm yapının kontrolünü elinde bulunduran, altındaki yapıların birbirleriyle iletişimini sağlayan, çalıştırıldıkça uygun dosyalamayı kontrol eden bir birim.

1. Ayar: Bu kısımda programın çalışmasıyla alakalı tüm ayarlar yapılır. Yazılan kaynak kodunun içerisine tekrar tekrar girilmesini önleyen bu birim hatadan uzak bir sistem geliştirmeyi sağlar.
2. Denetim Noktası: Deneyin her epochta kaydedilmesini ve istenildiği takdirde kaldığı yerden devam edebilmesini sağlar.
3. Tarih: Sistemdeki görselleştirici, günlük ve denetim noktasında kullanılan parametreleri kaydetmekle yükümlüdür.
4. Tahmin: İçinde bulundurduğu modeli uygun optimizasyon modeliyle eğitir. Eğitim esnasında her epochta validasyonunu sağlar. Modeli eğitmek için gerek verisetiyle olan entegrasyonu da tahmin birimi yapar. Problemden probleme değişecek tek kısım burasıdır.
    - Model: LSTM, CNN, Autoencoder gibi yapıların probleme göre uygulandığı kısım.
    - Optimizasyon: SGD, Adam, Adadelta gibi optimizasyon yöntemlerini ve gerekirse özel uygulamaların yapıldığı kısım.

- Veriset: Problemdeki verilerin okunduğu, verilerin normalizasyonunun yapıldığı ve diğer bileşenlere verilerin aktarıldığı kısım.

5. Raporlayıcı:
    - Görselleştirici: Gerekli görsel grafiklerin oluşturulduğu kısım.
    - Günlük: Raporlamak için gereken her türlü günlük bilgisini saklayan ve kaydeden kısım.

Önümüzdeki dönemde bu platformu kullanarak daha hızlı çözüme ulaşılmasını hedefliyoruz.

1.C. Gelecek dönem yapılacak çalışmalar

Bu dönem tüm iş paketleri üzerinde çalışılmıştır, fakat ağırlıklı olarak IP1,2,3,6,7 ve 9 üzerinde çalışmalar yapılmıştır. Önümüzdeki dönem içinde derin öğrenme tabanlı trend tespiti, opsiyon stratejisi eniyilemesi, büyük veri analizi ve çok etmenli sistem tasarımı konusunda çalışılmaya devam edilecektir. Bu dönem 2 konferans bildirisi yayınladık ve 1 dergi makalesi kabul edildi. Önümüzdeki dönem içinde 1 veya 2 adet konferans bildirisi göndermeyi hedefliyoruz. Şu anda hakem incelemesinde olan biradet dergi makalesi bulunmaktadır. 1 tane de tarama şeklinde dergi makalesi hazırlığımız da vardır. Bunun yanı sıra 1 veya 2 adet yeni dergi makalesi yazımı ve başvurusu da hedefler arasındadır.

1.D. Kaynakça

[1] F. Black and M. Scholes, “The Pricing of Options and Corporate Liabilities.”

[2] Z. Bodie, A. Kane, and A. J. Marcus, *Investments*. McGraw-Hill/Irwin, 2008.

[3] D. A. MacKenzie, *An engine, not a camera : how financial models shape markets*. MIT Press, 2006.

[4] J. D. MACBETH and L. J. MERVILLE, “An Empirical Examination of the Black-Scholes Call Option Pricing Model,” *J. Finance*, vol. 34, no. 5, pp. 1173–1186, Dec. 1979.

[5] N. B. Gultekin, R. J. Rogalski, and S. M. Tinic, “Option Pricing Model Estimates: Some Empirical Results,” *Financ. Manag.*, vol. 11, no. 1, p. 58, 1982.

[6] J. M. HUTCHINSON, A. W. LO, and T. POGGIO, “A Nonparametric Approach to Pricing and Hedging Derivative Securities Via Learning Networks,” *J. Finance*, vol. 49, no. 3, pp. 851–889, Jul. 1994.

[7] S. Figlewski, “Forecasting Volatility,” *Financ. Mark. Institutions Instruments*, vol. 6, no. 1, pp. 1–88, Feb. 1997.

[8] Y.-H. Wang, “Nonlinear neural network forecasting model for stock index option price: Hybrid GJR–GARCH approach,” *Expert Syst. Appl.*, vol. 36, no. 1, pp. 564–570, Jan. 2009.

[9] L. Tang and X. Diao, “Option pricing based on HMM and GARCH model,” in *2017 29th Chinese Control And Decision Conference (CCDC)*, 2017, pp. 3363–3368.

[10] M. Malliaris and L. Salchenberger, “Using neural networks to forecast the S&P 100 implied volatility,” *Neurocomputing*, vol. 10, no. 2, pp. 183–195, Mar. 1996.

[11] Y. Kim and D. Enke, “Using Neural Networks to Forecast Volatility for an Asset Allocation Strategy Based on the Target Volatility,” *Procedia Comput. Sci.*, vol. 95, pp. 281–286, Jan. 2016.

[12] F. Audrino and D. Colangelo, “Semi-parametric forecasts of the implied volatility surface using regression trees,” *Stat. Comput.*, vol. 20, no. 4, pp. 421–434, Oct. 2010.

[13] L. Montesdeoca and M. Niranjan, “Extending the feature set of a data-driven artificial neural network model of pricing financial options,” in *2016 IEEE Symposium Series on Computational Intelligence (SSCI)*, 2016, pp. 1–6.

[14] X. Liang, H. Zhang, J. Xiao, and Y. Chen, “Improving option price forecasts with neural networks and support vector regressions,” *Neurocomputing*, vol. 72, no. 13–15, pp. 3055–3065, Aug. 2009.

[15] H. Amilon, “A neural network versus Black-Scholes: a comparison of pricing and hedging performances,” *J. Forecast.*, vol. 22, no. 4, pp. 317–335, Jul. 2003.

[16] J. Yao, Y. Li, and C. L. Tan, “Option price forecasting using neural networks,” *Omega*, vol. 28, no. 4, pp. 455–466, Aug. 2000.

[17] Z. ltüzer Samur, “The Use of Artificial Neural Network in Option Pricing : The Case of S & P 100 Index Options.” 2009.

[18] N. Gradojevic, R. Gencay, and D. Kukolj, “Option Pricing With Modular Neural Networks,” *IEEE Trans. Neural Networks*, vol. 20, no. 4, pp. 626–637, Apr. 2009.

[19] M. J. Morelli, G. Montagna, O. Nicrosini, M. Treccani, M. Farina, and P. Amato, “Pricing financial derivatives with neural networks,” *Phys. A Stat. Mech. its Appl.*, vol. 338, no. 1–2, pp. 160–165, Jul. 2004.

[20] H.-C. Wu, “Pricing European options based on the fuzzy pattern of Black–Scholes formula,” *Comput. Oper. Res.*, vol. 31, no. 7, pp. 1069–1081, Jun. 2004.

[21] R. Gencay and R. Gibson, “Model Risk for European-Style Stock Index Options,” *IEEE Trans. Neural Networks*, vol. 18, no. 1, pp. 193–202, Jan. 2007.

[22] E. Turner, “THE BLACK-SCHOLES MODEL AND EXTENSIONS,” 2010.

[23] P. K. Naik and P. Padhi, “Stock Market Volatility and Equity Trading Volume: Empirical Examination from Brazil, Russia, India and China (BRIC),” *Glob. Bus. Rev.*, vol. 16, no. 5_suppl, pp. 28S-45S, Oct. 2015.

[24] K. Suzuki, T. Shimokawa, and T. Misawa, “An Agent-Based Approach to Option Pricing Anomalies,” *IEEE Trans. Evol. Comput.*, vol. 13, no. 1, pp. 19–32, Feb. 2009.

[25] S.-H. Poon and C. W. J. Granger, “Forecasting Volatility in Financial Markets: A Review,” *J. Econ. Lit.*, vol. 41, no. 2, pp. 478–539, Jun. 2003.

1.E. Şekil Listesi

Şekil 1. İki model içinde oluşturulmuş olan bir örnek yapay sinir ağı modellemesi 7
Şekil 2. LSTM hücresinin örnek hali 8
Şekil 3. Projede kullanılan LSTM Modelinin genel iskelet yapısı 9
Şekil 4. Genel olarak tasarlanan modellerin birleştirilmiş hali olan ağ 12
Şekil 5. Önerilen modelin aşamaları 15
Şekil 6. Destek ve direnç çizgileri 16
Şekil 7. Al ve sat noktaları 16
Şekil 8. Kullanılan Cuckoo Search Algoritması 17
Şekil 9. Volüm alt sınırına göre hata ortalaması (volüm, alt volüm eşiğidir, hata ortalaması ekseni, eşik değerinden daha küçük volümlü opsiyonların BS hatası ortalamasıdır, çizgiler eşik değerinden düşük völümlü opsiyonlara sahip BS hata varyansıdır, tüm veriler arasında eşik değerden daha düşük volümlü olan opsiyonların oranı her noktanın sağ üst kısmına yazılmıştır) 20
Şekil 10. BS hata histogramı 22
Şekil 11. BS ve modellerin ortalama hata ve hata varyansı (her biri 25 farklı doğrulama için) 23
Şekil 12. Eşik değere göre parasallık sınırı civarı ve uzağında kalan bölgelerdeki hara ortalama ve varyans değerleri (Daireler, parasallık sınırına belirtilen eşik değeri kadar uzaktaki opsiyonşarı üçgenler ise bu alanın dışında kalan opsiyonları belirtmektedir.Üçgenlerin ilgili eşik değeri ile oluşturduğu bölgedeki opsiyonların tüm opsiyonlara oranı yanlarında verilmiştir.) 24
Şekil 13. VS-BS/MLP dizaynı 25
Şekil 14. VS-MLP/MLP dizaynı 25
Şekil 15. C-BS/MLP design 25
Şekil 16. Eşik değerine bağlı ayrım oranı ve hata 26
Şekil 17. C-MLP/MLP dizayn 26
Şekil 18. C-MLP dinamik dizayn 27
Şekil 19. C-MLP dinamik dizaynında sınıflandırmada kullanılan eşik sayısına göre optimal maliyet 27
Şekil 20. Sabit veri boyutu için değişen çekirdek sayıları hız grafikleri 30
Şekil 21. Sabit veri boyutu için değişen çekirdek sayıları hız grafikleri (logaritmik) 31
Şekil 22. Sabit çekirdek sayısı için değişen veri büyüklüğü grafikleri 32
Şekil 23. Sabit çekirdek sayısı için değişen Veri Büyüklüğü grafikleri (logaritmik) 33
Şekil 24. Farklı Veri Büyüklükleri İçin Hızlandırma 34
Şekil 25. Benchmark Sonuçları 35
Şekil 26. Benchmark Sonuçları (Logaritmik) 36

1.F. Tablo Listesi

Tablo 1. MSE değerleri tüm agentlar ve orijinal veri arasında 10
Tablo 2. Kesinlik değerleri tüm agentlar ve orijinal veri arasında 10
Tablo 3. :DTW(dynamic time warping) değerleri tüm agentlar ve lstm arasında 11
Tablo 4. :MSE değerleri lstm decider ve tüm agentlar arası 11
Tablo 5. Kesinlik değerleri lstm decider ve tüm agentlar arası 11
Tablo 6. Dtw değerleri lstm decider ve tüm agentlar arası 11
Tablo 7. Korelasyon değerleri lstm decider ve tüm agentlar arası 12
Tablo 8. Evaluation of Proposal with different stock datas 17
Tablo 9 Ham veriseti 20
Tablo 10 BS formülünde kullanılan parametreler 21
Tablo 11. Revize edilmiş veri seti 22
Tablo 12 Öznitelikler 22
Tablo 13 Ortalama karesel hatalar (25 farklı setle elde edilen skorların en iyi ve en kötü değerleri ile bu sonuçların ortalaması ve varyansı) 23
Tablo 14 C-MLP dinamik dizaynında artan ayrım noktasına göre seçilen en iyi noktalar ve maliyetleri 28
Tablo 15. Dataset İstatislikleri 29
Tablo 16. Benchmark(#çekirdek vs veri buyuklugu) sonuclari(saniye) 35

1.G. Ekler

Proje kapsamında dönem içinde basılmış olan olan iki adet konferans bildirisi mevcuttur. Bunları önceki dönem verdiğimiz için tekrar eklemiyoruz. Kabul edilen dergi makalesi ile ilgili anlatımların büyük kısmını Bilimsel Gelişmeler kısmında aktardık. Kabul edilen makalenin online linki https://doi.org/10.1016/j.asoc.2018.04.024 şeklindedir. Dolayısıyla bu aşamada herhangi bir ek bulunmamaktadır.

2. Dönem İçinde İdari Gelişmeler

Proje kapsamında 1 yürütücü, 1 danışman, bilgisayar mühendisliği alanında 2 doktora öğrencisi ve işletme/finans alanında 1 yüksek lisans öğrencisi ile çalışılması öngörülmüştü. Danışman olarak projede görev yapması planlanan Doç. Dr. Ekin Tokat Tübitak destekli 1 senelik yurt dışı görevlendirmesi ile 1 Temmuz 2016-1 Temmuz 2017 tarihleri arasında ABD'de bulunmuş olduğundan projenin önceki döneminde çalışmamıştır. Kendisi önceki dönem içinde Türkiye'ye dönmüş ve proje kapsamındaki çalışmalarına başlamıştır.

Geçtiğimiz dönem proje kapsamında doktora bursiyeri olarak çalışmakta olan İlknur Uçar doktorta programını bıraktığı için projeden de 31 Ağustos 2017 tarihi itibarıyle ayrılmıştır. Onun yerine projeye iki adet burslu ücretli yüksek lisans bursiyeri projede çalışmaya başlamıştır. Fakat bunlardan biri de bu dönem içinde kısa bir süre çalıştıktan sonra projeden ayrılmıştır. Fakat iki yeni ücretli yüksek lisans bursiyeri daha proje ekibine katılmış ve çalışmalara başlamışlardır.

Projeye yeni katılan iki adet yüksek lisans bursiyeri Gökçe Dilek Kısbet ve Betül Bakar'dır. Gökçe Dilek Kısbet, Kaan Kaya'nın yerini almıştır ve finansal alım-satım modellerinde kullanılmak üzere bir çok etmenli sistem tasarımı üzerinde yüksek lisans tez çalışmasını gerçekleştirecektir. Betül Bakar ise bu aşamada zaman serisi tahmin modelleri ve derin öğrenme modelleri üzerinde çalışacaktır. Daha sonra kendisi projedeki diğer iş paketlerine de katkı verecek şekilde görevlendirilebilecektir.

3. Proje Çalışma Takvimine Uygun Yürümüyorsa Gerekçeleri

Proje takviminde bazı kaymalar olsa da çalışmaların ilerleyişinde ve projenin gidişatında önemli bir problem görülmemektedir. Bu aşamada 3 iş paketinde başarı kriterlerini şimdiden sağlamış durumdayız. Diğer iş paketlerinde de benzer bir sonucun elde edileceğini öngörmekteyiz. Her ne kadar planda büyük ölçüde proje ekibindeki değişikliklere bağlı olarak zorunlu bazı oynamalar olsa da projenin genel işleyişinde bir sıkıntı olduğunu düşünmüyorum.

4. Bir Sonraki Dönemde Yapılması Planlanan Çalışmalar

Geçtiğimiz dönemlerde başlanan çalışmalara devam edilmesi ve projenin planlanan şekilde tamamlanması öngörülmektedir. Bu dönemde büyük veri işleme ve çok etmenli sistem tasarımı ile ilgili çalışmalara da devam edilmesi öngörülmektedir. Derin öğrenme ile Trend tahmini ve gösterge eniyilemesi işlemleri büyük ölçüde tamamlandığından ağırlığı opsiyon stratejilerini eniyilemesine vermeyi planlıyoruz.

Bu dönemde elde edilen çıkarımların bildiri / makaleye dönüştürülmesi de amaçlanmaktadır. Bu dönemde 1-2 konferans makalesi 2 veya 3 de dergi makalesi oluşturulması hedeflenmektedir.

5. Destekleyen Diğer Kuruluşlarla İlgili Sorunlar Varsa Ayrıntıları ve Çözüm Önerileri

Başka bir kurumdan destek almıyoruz.

6. Dönem İçinde Proje Kapsamında Yapılan veya hazırlanan Yayımlar ve Toplantılarda Sunulan Bildiriler

Sıra	Çıktı türü	Yazarlar	Başlık	Yayın yeri	Durumu *
1	Uluslararası konferans bildirisi	Sezer, O., Ozbayoglu, A.M., Dogdu	A Deep Neural-Network based Stock Trading System based on Evolutionary Optimized Technical Analysis Parameters	Procedia Computer Science, Vol 114, pp 473-480, CAS 2017, Chicago, IL, October 30 - November 1, 2017	Yayınlandı
2	Uluslararası konferans bildirisi	Güdelek, M.U., Bölük, A., Ozbayoglu, A.M.	A Deep Learning based Stock Trading Model with 2-D CNN Trend Detection	CiFER 2017 for SSCI 2017	Yayınlandı
3	Dergi makalesi	Sezer, O., Ozbayoglu, A.M.	Algorithmic Financial Trading with Deep Convolutional Neural Networks: Time Series to Image Conversion Approach	Applied Soft Computing	Yayınlanmaya kabul edildi
3	Dergi makalesi	Sezer, O., Ozbayoglu, A.M.	Financial Trading Model with Stock Bar Chart Image Time Series with Deep Convolutional Neural Networks	Intelligent Automation and Soft Computing	Hakem değerlendirmesinde

* Hakem değerlendirmesinde, Yayınlanmaya kabul edildi, Yayınlandı